



本科生毕业论文（设计）

题目：基于轨迹调制和强化学习的
小型四足机器人运动控制方法

姓 名 赵子健

学 号 20308269

院 系 计算机学院

专 业 计算机科学与技术

指导教师 陈刚（教授）

2024 年 5 月 9 日

基于轨迹调制和强化学习的
小型四足机器人运动控制方法

Motion Control Method for Small Quadruped Robots

Based on Trajectory Modulation and Reinforcement Learning

姓 名	赵子健
学 号	20308269
院 系	计算机学院
专 业	计算机科学与技术
指导教师	陈刚 (教授)

2024 年 5 月 9 日

学术诚信声明

本人郑重声明：所呈交的毕业论文（设计），是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文（设计）不包含任何其他个人或集体已经发表或撰写过的作品成果。对本论文（设计）的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本论文（设计）的知识产权归属于培养单位。本人完全意识到本声明的法律结果由本人承担。

作者签名：

日 期： 年 月 日

【摘 要】

四足机器人凭借其稳定性和灵活性，在许多领域如科研、军事、救援等方面都得到了广泛应用。四足机器人的运动控制已成为机器人领域最热门的研究课题之一。

目前常见的控制方法可以分为基于建模计算的方法和基于强化学习的方法。然而，基于建模计算的方法往往需要专家知识，并需要为不同的场景设计不同的方法，这需要大量的计算和调试。为了解决这些问题，强化学习方法受到了广泛关注，该方法可以使机器人能够自适应地与环境进行交互，并学习适当的运动策略。然而过去的大部分强化学习方法对硬件要求较高，在训练过程中具有较大的计算开销，并且在计算能力较低且感知能力较差的小型机器人上表现不佳。

因此，本文以轻量级的 ARS 算法为基础，将其与贝塞尔曲线结合设计了 ARS-Bezier 方法，以提升模型的学习能力与学习效率、降低学习难度。另外本文进一步提出了环境随机化的方法，以使通过算法学习到的策略具有更好的迁移性。本文的主要研究内容如下：

首先，本文以课题组研发的机器鼠 NeRmo 为研究对象，研究分析了机器鼠的运动控制方法，并进行了正逆向运动学的建模。

之后，本文分析了贝塞尔曲线的基本性质，进行了简单的证明，并介绍了基于贝塞尔轨迹四足机器人控制方法。

接下来，针对机器鼠的结构本文设计了 ARS 框架，并为了提升模型的学习能力，设计了一种基于贝塞尔曲线辅助的控制方法——ARS-Bezier。此外本文还提出了环境随机化的方法，使机器人能够学习到更加普适的运动策略。

然后，本文在仿真环境和实际环境中进行了一系列实验，通过对比实验证明了 ARS-Bezier 方法的有效性，并分析了在不同场景下通过环境随机化学到的运动策略的表现，最后展示了实际搭建机器鼠以及将算法烧录的流程，并验证了运动策略在实际场景下的有效性。

本文代码已发布于 <https://github.com/RS2002/Robot-mouse>。

关键词： 小型四足机器人运动控制，贝塞尔曲线，强化学习，增强型随机搜索算法（Augmented Random Search, ARS）算法

[ABSTRACT]

Quadruped robots have gained significant attention in various fields, including scientific research, military applications, and rescue operations, due to their stability and flexibility. As a result, motion control for quadruped robots has become a popular research topic in the field of robotics.

Currently, there are two common approaches to control quadruped robots: model-based methods and reinforcement learning-based methods. Model-based methods often require extensive expert knowledge, computation, and debugging. Moreover, these methods lack transferability and require designing different approaches for different scenarios. In contrast, reinforcement learning methods have attracted significant interest as they enable robots to interact adaptively with the environment and learn suitable motion strategies. However, previous reinforcement learning methods often have high hardware requirements, substantial computational costs during training, and perform poorly on small robots with limited computational and perceptual capabilities.

To address these challenges, we propose the ARS-Bezier method based on the lightweight Augmented Random Search (ARS) algorithm. The ARS-Bezier method combines the ARS algorithm with Bezier curves to enhance the model's learning ability, improve learning efficiency, and reduce learning difficulty. Additionally, we introduce the method of environment randomization to enhance the transferability of learned policies. The main contributions of this paper are as follows:

Firstly, we focus on the motion control methods of the self-developed robot mouse NeRmo. This includes the modeling of forward and inverse kinematics.

Next, we analyze the fundamental properties of Bezier curves and provide a simple proof. Then we deploy Bezier trajectories on the robot mouse.

Subsequently, based on the robot mouse's structure, we design the ARS framework and propose the ARS-Bezier control method, which utilizes Bezier curves to enhance the model's learning ability. Additionally, we introduce an environment randomization method to enable the robot to learn more versatile motion strategies.

Then, we conduct a series of experiments in both simulation and real environments to demonstrate the effectiveness of the ARS-Bezier method. We compare the experimental results and analyze the performance of learned motion strategies through environment

randomization in different scenarios. Furthermore, we showcase the process of building the actual robot mouse, burning the algorithm, and verify the effectiveness of the motion strategies in real-world scenarios.

The code for this paper has been published at <https://github.com/RS2002/Robot-mouse>.

Keywords: Small Quadruped Robot Motion Control, Bezier Curves, Reinforcement Learning, Augmented Random Search (ARS) Algorithm

目录

1	绪论	1
1.1	选题背景与意义	1
1.2	国内外研究现状和相关工作	2
1.3	本文工作与主要贡献	9
1.4	本文的论文结构与章节安排	9
2	基于贝塞尔曲线的四足机器人运动控制方法	11
2.1	引言	11
2.2	机器人运动学建模	11
2.3	贝塞尔曲线	15
2.4	基于贝塞尔曲线的运动轨迹生成器	17
2.5	本章小结	21
3	轨迹调制辅助的强化学习四足机器人运动控制方法	22
3.1	引言	22
3.2	强化学习概述	22
3.3	基于 ARS 算法的强化学习方法	23
3.4	基于贝塞尔轨迹辅助的 ARS 运动控制方法	27
3.5	本章小结	30
4	实验结果与分析	31
4.1	引言	31
4.2	仿真结果分析	31
4.3	实物验证	42
4.4	结论	46
5	总结与展望	47
5.1	总结	47

5.2 展望	47
参考文献	49
致谢	54
在读期间发表的学术论文与取得的研究成果	55

插图目录

1.1	“机器人”概念来源 ^[1]	1
1.2	早期四足机器人	3
1.3	波士顿公司机器人	4
1.4	高校研发机器人	5
1.5	国内高校研发的机器人	5
1.6	国内企业研发的机器人	6
2.1	机器鼠腿部结构：其中 OE 两点是电机位置、D 点为腿部末端点位置，红线代表绳子。	12
2.2	机器鼠足端工作空间	14
2.3	基于贝塞尔曲线的机器人腿部运动轨迹	19
3.1	ARS 与 BRS 算法流程图：其中黑色框代表各方法的相同的步骤，蓝色、绿色、红色、紫色框分别表示 ARS-v1、ARS-v2、ARS-top、BRS 算法特有的步骤	24
3.2	MuJoCo 环境中的随机地形	29
3.3	ARS-Bezier 方法流程图	29
4.1	MuJoCo ^[69] 图形界面：界面左侧提供了实时操作功能，界面中间是仿真环境，界面右侧可以实时显示控制参数和传感器信息	31
4.2	MuJoCo ^[69] 仿真环境中机器鼠左前腿悬空	32
4.3	机器鼠左前腿悬空状态下目标贝塞尔运动轨迹与实际运动轨迹的对比	33
4.4	仿真环境中的四个不同场景	33
4.5	平地仿真环境中机器鼠的运动情况	34
4.6	有障碍物场景下机器鼠的左前腿末端点运动轨迹：两列分别代表使用基于贝塞尔轨迹的控制方法和基于椭圆轨迹的控制方法，三行分别代表三种不同障碍场景	37
4.7	各场景下不同算法的训练过程	38

4.8	随机环境下的训练过程	39
4.9	机器鼠在仿真环境中通过障碍物的状态示意图：两列分别代表使用 ARS-Beizer(simple) 算法和 ARS-Beizer 算法，三行分别代表三种不同障碍场景	39
4.10	有障碍物场景下机器鼠的左前腿末端点运动轨迹：两列分别代表使用 ARS-Beizer(simple) 算法和 ARS-Beizer 算法，三行分别代表三种不同障碍场景	40
4.11	不同策略下前进过程中的横向偏移	41
4.12	不同策略下前进过程中的三轴加速度	41
4.13	机器鼠 NeRmo Lite 结构	42
4.14	实际搭建的机器鼠图片	43
4.15	机器鼠电气元件的简化原理图	44
4.16	机器鼠各器件间的连接方法：图中红字表示该器件的名称，黄色和绿色的线段表示连线情况	44
4.17	机器鼠左前腿实际控制情况：图中红色曲线为左前腿控制的目标曲线，蓝色星号位置表示机器人在实际运动中所达到的位置	45
4.18	机器鼠在实际环境中运动情况：子标题代表开始运动的时间，图中蓝色点代表腿部末端点在运动中实际到达的位置，红色线条代表腿部末端点运动轨迹	45

表格目录

2.1	贝塞尔曲线控制点：其中 τ 和 ψ 为参数	18
3.1	ARS-Bezier 算法的贝塞尔曲线控制点	28
3.2	ARS-Bezier 算法参数	30
4.1	不同场景下机器鼠前进距离	36
4.2	不同场景下机器鼠能通过的最大障碍物高度	36
4.3	不同策略下前进过程中的三轴加速度标准差	36

1 绪论

1.1 选题背景与意义

机器人这一概念首次出现在作家卡佩克于 1920 年写作的书中，1939 年工程师德沃尔发明了一台名为埃列克特罗（Electro）的机器人，这被认为是第一台机器人设备。如今，机器人已经广泛应用于各个领域，包括医疗、交通、学习等等。特别是近年来人工智能的发展，使得机器人在运动、理解、交互等方面都取得了巨大的进步。人工智能和机器人领域的发展很大程度上解放了现代社会的脑力劳动和体力劳动，智能机器人已经成为各个国家发展的重要推动力之一。近年来我国也提出了“中国制造 2025”智能制造发展策略，大力支持相关领域的发展。



图 1.1 “机器人”概念来源^[1]

移动机器人是机器人领域的一个重要研究领域，一直备受关注。在军事、救援和勘测等领域，移动机器人已经展现出其不可替代的作用，特别是在危险地区和狭窄地形中。目前，移动机器人主要分为轮式、履带式和腿足式三种类型。轮式机器人通常由多个轮子组成，其运动方式类似于汽车，具有快速移动和良好的转向能力等优点。然而，轮式机器人在跨越障碍物方面的能力相对较弱。为了克服这个问题，人们开发了履带式机器人，其运动方式类似于坦克，通过履带能够较

好地跨越简单的障碍物，并在不平坦的地面上保持良好的运动效果。然而，由于履带系统的设计，履带式机器人通常具有较慢的运动速度，并且一般具有较大的尺寸和重量，导致能耗较高。目前，这两种类型的机器人主要在货物运输等领域得到广泛应用。为了解决在复杂地形中的灵活移动问题，人们研发了仿生机器人，除腿足式机器人外还包括蛇形和鸟形等特殊结构的机器人，可用于更特殊的场景。腿足式机器人通常模仿动物的肢体结构设计，模拟动物的行走方式，并具备更多的移动姿势，如跳跃、小跑、爬行等，具有较强的灵活性。相比轮式和履带式机器人，腿足式机器人通常更小巧灵活，具有更好的避障和越障能力，更适用于军事勘测、抢险救灾以及恶劣复杂地形的勘探等领域。

目前常见的腿足式机器人又可分为双足、四足和六足。双足机器人稳定性较差、控制难度较高，而六足机器人一般结构较为复杂，难以通过狭窄空间。四足机器人则很好地解决了这些问题，在运动稳定性和结构复杂性之间保持了较好的平衡。目前，四足机器人的运动控制方式主要包括基于建模计算和基于强化学习两类。基于建模计算的方法通常需要建立约束和优化目标，以求得最优解。然而，这种方法常常具有较高的控制难度和计算复杂度。基于数学建模的方法需要准确的目标几何模型，计算开销较大，并且容易导致机器人行为单一、适应性较差，难以在实际领域中应用。

相比之下，基于强化学习的控制方法具有一定的优势。强化学习方法可以使机器人通过与环境的交互来自适应地学习，并具有较高的适应能力，可以克服基于建模计算的方法在不同场景间迁移的问题。然而，尽管强化学习在理论上具有许多优点，但在实际部署和使用时也常常面临稀疏奖励、模型难以收敛、模型容量有限等各种问题。此外，不同的奖励函数和观测空间也会对学习结果产生很大影响。针对不同机器人结构特点，设计合适的强化学习方法是必要的。本文基于实验室研发的机器鼠 NeRmo^[2]，设计了一套基于轨迹调制辅助的适合小型机器人的控制方法。

1.2 国内外研究现状和相关工作

国内外对于四足仿生机械结构都有着很久的研究历史。早期的研究成果包括中国的“木牛流马”和欧洲中世纪的“机械马”。这些机械装置借鉴了真实马的形态和运动特征，通过复杂的机械结构模拟了马的步态和运动。近年来随着电子计算机的发展，四足仿生机器人的研究也由最初的以机械结构和控制方法为主逐渐转向仿生机器人的智能化研究。下面将介绍国内外四足机器人代表性的研究成果。

1.2.1 四足机器人研究现状

1.2.1.1 国外四足机器人研究现状

关于四足机器人的研究最早可追溯至美国通用公司于 1968 年发布的制四足电控步行车 Walking Truck^[3]。尽管这款机器人仍然需要人工控制，但它标志着四足机器人的初步出现。同年，美国南加州大学团队成功研制出了一台名为 Phony Pony 的真正意义上的四足机器人^[4]。每条腿包含两个自由度，能够实现小跑和爬行等简单动作。然而，这些早期的四足机器人并未引入与仿生学相关的概念。

到了上世纪七八十年代，仿生机器人逐渐得到研发，俄亥俄州立大学研制了一款名为 OSU 的六腿类昆虫机器人。随后，日本东京工业大学的 Hirose 团队将仿生学引入四足机器人的开发中，参考蜘蛛的结构研发出了许多系列的四足机器人，包括 KUMO^[5]、PV-II^[6]和 TITAN^[7]等。随着仿生四足机器人的发展，越来越多的传感器被加入机器人中，用于机器人感知环境，并实现自主决策。同时，机器人的机械结构也变得更加多样化，以实现更多步态、更好地适应环境，并实现更高的运动速度。在 20 世纪末，加拿大麦吉尔大学研制出了名为 SCOUT-II^[8]的机器人，通过在腿部添加弹簧结构，实现了更强的跳跃功能，并取得了极快的运动速度。




图 1.2 早期四足机器人

二十一世纪以来，四足机器人的研究吸引了越来越多的团队的关注，并在军事、勘测和科研领域得到广泛应用。其中，美国的波士顿动力公司在这一领域做出了重要贡献。早在 2004 年，波士顿动力就研发了小型仿生狗机器人 LittleDog^[9]。LittleDog 的每条腿都包含三个自由度，使得腿部能够在三维空间中运动。相较于传统只有两个自由度的腿部，LittleDog 具备更好的转向功能。基于对 LittleDog 的研究基础，波士顿动力在 2005 年发布了大型液压驱动四足机器人 BigDog^[10]。BigDog 后续发布了多个更新版本，具备快速运动、高稳定性和高负载能力等优点，成为了后来四足机器人的主流形态。2008 年，波士顿动力发布了 BigDog 的继任者 AlphaDog。AlphaDog 具有更大的负载能力，能够在恶劣环境下进行自主行动，广

泛应用于美国的军事领域。2015 年，波士顿动力推出了基于液压驱动的四足机器人 Spot^[11]，这是他们最成功的产品之一。Spot 配备了多种传感器，可以在复杂环境中行走和定位。它还具备出色的稳定性和平衡性，能够执行各种动作，如跳跃、爬楼梯和越过障碍物。Spot 在许多高校的相关科研中得到了广泛应用。此外，波士顿动力还不断研发其他动物形态的仿生四足机器人，例如他们开发了猫型机器人 WildCat^[12]。这些机器人的设计灵感来自于真实动物的运动特点，旨在实现更高的速度和机动性。




图 1.3 波士顿公司机器人

作为计算机、机器人、电子领域的顶尖高校，瑞士苏黎世联邦理工学院（ETH）和美国麻省理工学院（MIT）在四足机器人的研究上都做出了巨大贡献。MIT 最为著名的四足机器人当属 Cheetah^[13]，这是一款豹型机器人，运动速度可达 48km/h，并且在机械结构和机体材料方面都进行了创新性设计，大幅降低了机器人的运动能耗。基于此，MIT 还研制了 Mini Cheetah^[14]，一款模块化的小型四足机器人，具有出色的机动性和鲁棒性。该机器人可以进行各种动作，如翻滚、跳跃和快速行走，展示了四足机器人技术的巨大潜力。同期，ETH 也研制了四足机器人 ANYmal^[15]，这是一款具有高度自主性和适应性的机器人，旨在应对各种复杂的环境和任务。它具有全地形移动能力，可以在不平坦的地面上行走、攀爬楼梯和穿越障碍物。ANYmal 还配备了传感器套件，包括摄像头、激光雷达和惯性测量单元，以感知和理解周围环境。

1.2.1.2 国内四足机器人研究现状

国内对于机器人的研究起步相对较晚，早期的研究主要集中在高校和科研院所。上海交通大学于 1991 年率先开始相关的研究并研制了仿生马机器人 JTUWM^[16]，并基于该平台率先展开有关神经网络的智能控制算法的研究。2005 年左右哈尔滨工业大学与清华大学团队相继研制了 HIT-HYBTOR^[17]和 Biosbot^[18]四足机器人。到了 2010 年，依托于 863 计划，许多高校开始研制液压驱动的四足机器人，如浙江大学的赤兔机器人^[19]将激光雷达、深度相机等多种传感器加入四足机器人当中，




(a) Cheetah^[13]




(b) ANYmal^[15]

图 1.4 高校研发机器人


大幅提升了机器人的感知能力；上海大学研发了采用高功率密度电机直接驱动的四足机器人 XDog^[20]，并使用了碳纤维等轻量化材料大幅降低机器人的质量。



(a) 浙江大学赤兔机器人^[19]



(b) 上海大学 XDog 机器人^[20]




(c) 北京理工大学 SQuRo 机器人^[21]

图 1.5 国内高校研发的机器人

北京理工大学于近年推出多代小型机器鼠 SQuRo^[21]，由最初的轮式与腿式混合结构发展到目前的纯四足结构，可以实现多种复杂的运动。小型机器人由于内部空间较少，一般腿部自由度也相对较少，同时由于其膝关节处的空间较小不足以放置舵机，因此一般会通过特殊方式将大型机器人膝关节处的舵机转移。SQuRo 每条腿包含两个自由度，通过在大腿根部放置额外电机使用杆式结构带动膝关节转动。本文使用的机器鼠 NeRmo^[2]是与之结构类似的小型机器鼠，不同的是 NeRmo 采用绳驱的方式将膝关节处的电机转移到大腿根部，相比与 SQuRo 的连杆结构占据的空间更小，进而可以为其余结构留出更充分的空间。

近年来，国内的一些科技公司也开始积极参与四足机器人的研究。在 2021 年，许多机器人相继问世，其中包括腾讯推出的机器狗 Max、小米发布的机器狗 CyberDog、云深科技的绝影 X20、优宝特的大型 YoBoGo，以及宇树科技发布的 Go1 机器狗。这些机器人逐渐走入了大众的视野。例如，在 2021 年，宇树 A1 机

器狗登上了春晚舞台，引起了广泛关注；在 2023 年杭州亚洲运动会上，宇树科技、小远机器人、迅蚁科技和哈智机器人等公司的机器人则展示了跳舞和捡球等技能，给观众留下了深刻的印象。



(a) 腾讯 Max 机器人^[22]



(b) 小米 CyberDog 机器人^[23]



(c) 云深科技绝影 X20^[24]

图 1.6 国内企业研发的机器人

1.2.2 四足机器人控制方法研究现状

1.2.2.1 基于建模计算的控制方法研究现状

对于四足机器人的控制方法，常见的分类可以分为基于建模计算和基于强化学习两类。基于建模计算的控制方法通常需要建立约束和优化目标，以求得最优解。传统的基于建模计算的方法需要获取完整的环境信息和机器人的状态信息。首先通过计算和估计等方法，获取机器人的运动速度、加速度、角速度等信息，然后结合环境地形的几何信息、摩擦力等条件，进行计算并建立优化模型，以求解下一步机器人的动作。

早期具有代表性的方法包括零力矩点 (Zero Moment Point, ZMP)^[25] 和弹簧倒立摆 (Spring Loaded Inverted Pendulum, SLIP) 模型^[26]。ZMP 模型通过计算机器人身体上的零力矩点位置来确定机器人的稳定性。然而，该方法难以应用于复杂的地形环境，对于多接触点和三维运动的机器人控制有限；SLIP 模型是一种简化的机器人步态模型，用于描述机器人在跳跃和奔跑等高速运动时的动力学行为，可以预测机器人的跳跃高度和跳跃时间等参数。

近年来，还出现了一些新的方法，如虚拟模型控制 (Virtual Model Control, VMC)^[27] 和模型预测控制 (Model Predictive Control, MPC)^[28]。VMC 是一种基于模型的控制方法，通过构建虚拟模型和实际模型之间的误差来调整控制指令，实现机器人的自适应动态步态控制，具有较好的鲁棒性和适应性，但需要精确的模型参数和较高的计算能力；MPC 是一种基于优化的控制方法，通过建立机器人的动力学模型和运动约束条件，在每个控制时刻解决一个优化问题，以求得最佳的

控制指令,具有较强的优化能力和适应性。然而 MPC 计算复杂度较高,对实时性要求较高,并且对模型的准确性和约束条件的选择较为敏感。

由于基于数学建模的方法需要准确的目标几何模型,计算开销较大,并且容易导致机器人行为单一、适应性较差,难以在实际领域中应用,因此近年来的研究主要集中在通过强化学习训练机器人自适应地从环境中学习行动策略。

1.2.2.2 基于强化学习的控制方法研究现状

强化学习在机器人控制领域已经有几十年的发展历史。根据不同的维度,可以对强化学习方法进行分类。在行动决策层面上,常见的分类包括基于价值的方法和基于策略的方法^[29]。在学习方法的层面上,可以分为在线学习和离线学习。在环境探索方面,也可以分为 on-policy 和 off-policy 两种方法。

另一个常见的分类方法是基于是否依赖模型进行划分,可以分为有模型和无模型两种^[30]。有模型的方法首先通过大量数据构建环境模型,然后在该模型上训练控制策略,无需与真实环境进行交互。这种方法具有较高的数据利用率和较低的学习成本,可以更快地训练并且更容易使模型收敛。例如,Gen 等人提出的基于策略迭代的双足机器人运动控制方法属于基于模型的方法^[31]。然而对于机器人来说,建立精确的环境模型非常困难,因此无模型的方法变得更加流行,如 DQN^[32]、A3C^[33]、PPO^[34]等。这些方法在机器人控制领域的强化学习研究中占据主导地位。Minoru 等人提出了基于视觉增强的 Q-Learning 算法^[35],Haarnoja 等人提出了更加稳定高效的 Soft Actor-Critic 方法^[36]。

传统端到端的强化学习方法常常面临学习效率低和学习能力差的问题^[37],在实际应用中可能导致机器人运动到非安全区域。为了解决这些问题,基于模型的强化学习成为一种有效的方法。例如,Wang 等人提出了一种基于 SAC 的分层强化学习结构,可以减少学习过程中的探索空间^[38]。

此外,为了使机器人能够适应不同的环境,迁移学习^[39]、元学习^[40]、课程学习^[41]和终身学习^[42]等也成为近年来的研究热点。这些方法的核心思想是让机器人在简单环境中学习,并将所获得的先验知识应用于新的复杂环境。Finn 等人提出了一种在线元学习方法,使机器人能够连续学习不同的任务^[43]。

近年来,中枢模式发生器 (Central Pattern Generator, CPG)^[44]被引入机器人运动控制中。CPG 原本是生物神经网络,可以调节生物运动并产生周期性的运动模式。在机器人运动控制领域,CPG 被用于帮助机器人生成周期性的运动步态轨迹,从而控制机器人的运动。这种方法也可以与强化学习相结合,通过步态轨迹辅助机器人的强化学习。例如,Shi 等人提出了 ETG-RL 方法^[45],该方法通过进化轨迹

生成器优化给定任务的输出轨迹形状，而 Rahme 等人提出了基于贝塞尔曲线辅助的强化学习方法^[46]。

近期随着大型语言模型 (Large Language Model, LLM) 如 GPT^[47] 的出现，人们开始广泛应用这些模型和自然语言处理模型于各个领域，包括信号处理^[48-49]、计算音乐^[50-51]、自动驾驶^[52-53] 等。相较于传统的神经网络，大型模型通常具有更多的模型参数和更大的训练数据集，因此具备更强的泛化性能。强化学习与大型模型相互促进，强化学习不仅可以帮助大型模型更好地获取生成结果的反馈（例如通过人类反馈进行强化学习，即 RLHF^[54]），而且大型模型也可以与强化学习相结合，用于机器人和自动驾驶等领域的控制。Li 等人^[55] 通过将 LLM 与大型视觉模型 (Large Vision Model, LVM) 结合起来，将人类的指令与环境信息转化为机器人的控制代码；Sakib 等人^[56] 则利用 LLM 对机器人进行任务规划，以便为机器人的运动规划确定合适的顺序。

然而，在机器人强化学习领域，仍存在着一个重要问题，即从仿真环境到真实环境的迁移。由于机器人的成本较高，通常的做法是首先在仿真环境中对机器人进行训练，然后将在仿真环境中学到的策略迁移到真实环境中。相较于直接在真实环境中进行训练，仿真环境训练具有成本低、可并行化和风险较低等优点。然而，由于仿真环境无法完全模拟真实环境，因此在仿真环境到真实环境的迁移过程中通常需要进行一些调整。为了减小仿真环境与真实环境之间的差距，常用的两种方法是提升仿真器的准确性，或者使用随机化训练的方法来提高在仿真环境中学到的策略的鲁棒性^[46]。此外，Hwangbo 等人^[57] 提出了一种结合仿真和真实环境的训练方法，大大降低了从仿真到真实环境迁移的计算开销。

此外，目前针对机器人运动控制的强化学习方法主要集中在大型机器人上，而对小型机器人的研究相对较少。然而，小型机器人具有感知能力和计算能力有限的特点，传统的强化学习方法在小型机器人上的应用效果并不理想。小型机器人通常具有较小的传感器套件和计算资源，这限制了其对环境的感知和学习能力。传统的强化学习方法通常需要大量的观测数据和计算资源来训练模型，这在小型机器人中可能是不可行的。但由于小型机器人由于其体型和结构的优势，在军事、勘测、救援等任务中具有广泛的应用前景，针对小型机器人设计适用的强化学习方法具有重要意义，这也是本文的研究重点。具体来说，本文通过使用轻量级的强化学习方法，以减少训练期间的计算开销，使其适用于小型机器人。同时，本文还设计了一种基于轨迹辅助的强化学习控制方法，称为 ARS-Bezier，旨在降低训练期间的学习难度，并进一步减少训练期间的计算开销。通过这些方法，我们可以有效地应用强化学习于小型机器人。

1.3 本文工作与主要贡献

本文通过将轻量级强化学习方法——增强型随机搜索算法 (Augmented Random Search, ARS)^[58]与基于贝塞尔轨迹的控制方法^[59]相结合,提出了一种名为 ARS-Bezier 的方法。与传统的端到端控制方法不同,ARS-Bezier 方法利用贝塞尔曲线的原理,设计了适当的控制点关系,并通过 ARS 算法动态调整控制点参数,即该方法的动作空间为贝塞尔轨迹的控制参数。此外,本文还通过设计随机环境的方法,使机器人在随机生成的复杂地形上进行训练,从而学习适用于多种未知地形的运动策略。

与类似的方案^[46]相比,ARS-Bezier 方法更符合贝塞尔轨迹的控制原理,在各种场景下都取得了优于以往方案的效果。此外,借助贝塞尔曲线,ARS-Bezier 方法相对于传统的 ARS 能够更快地收敛,进一步降低计算开销。本文的主要贡献包括以下三点:

(1) 通过对贝塞尔曲线的基本性质进行分析和证明,并通过公式推导进一步完善了基于贝塞尔轨迹控制方法^[59]的假设。

(2) 提出了基于贝塞尔轨迹与 ARS 算法的轨迹辅助强化学习控制方法——ARS-Bezier,并通过环境随机化的方法训练机器人以获得更普适的运动策略。该方法计算开销较小,适用于小型机器人的运动控制。

(3) 在仿真实验中,通过设计四种不同的场景来比较不同强化学习控制方法的性能,证明了提出的 ARS-Bezier 方法相比传统方法具有更快的收敛速度。此外,通过测试机器人能够克服的最高障碍物高度以及机器人在相同步数下前进的距离,证明了 ARS-Bezier 在性能上超过了 Rahme 等人^[46]提出的类似方法。最后,在实际环境中搭建机器人并烧入控制策略,验证了提出方法在实际环境中的有效性。

1.4 本文的论文结构与章节安排

本文首先概述了四足机器人及其控制方法的研究现状,接着详细介绍了本文所采用的仿真和实机实验平台,然后探讨了基于贝塞尔曲线和基于强化学习的四足机器人运动控制方法,并进行了相关的仿真实验。在此基础上,提出了本文的方法——一种基于贝塞尔曲线辅助的轻量级强化学习控制方法。最后,通过仿真实验对实验结果进行了深入分析,并对搭建了实际机器人对算法进行测试。本文内容共五个章节,具体安排如下:

第一章: 绪论。首先介绍了四足机器人的发展背景以及选题的意义。随后以实际机器人和算法为例介绍了国内外四足机器人及其控制方法的发展历史和现状,

并对其中代表性的模型进行了简要分析。

第二章：基于贝塞尔曲线的四足机器人运动控制方法。首先通过正逆向建模的方式对本文的硬件平台——机器鼠 NeRmo 的四足控制方式进行了分析，并对足端控制空间进行了详细的探讨。之后介绍了贝塞尔曲线，并对其基本性质进行了推导和证明，接着详细说明了基于贝塞尔曲线的四足机器人运动控制方法的设计原理。

第三章：轨迹调制辅助的强化学习四足机器人运动控制方法。首先介绍了强化学习的基本原理以及 ARS 算法^[58]，并介绍了 ARS 算法的几种变体。然后设计了基于 ARS 算法的机器鼠强化学习框架。最后进一步将 ARS 算法与贝塞尔曲线结合，提出了 ARS-Bezier 方法，并设计了仿真环境中的随机环境，以提升策略在不同场景下的迁移性。

第四章：实验结果与分析。首先在仿真环境下对提出的 Bezier 控制方法、ARS-Bezier 方法等进行测试，与几种不同的强化学习方法进行对比实验。然后使用环境随机化的方法训练模型，测试了学习到的策略在不同场景下的性能。最后进行实机测试，介绍了 NeRmo 的基本硬件组成以及实际搭建机器人和调试的过程，并成功将运动策略部署到实际机器鼠中。

第五章：总结与展望。首先对本文的研究内容进行了总结，然后提出了一些不足之处并展望了未来的研究方向。

2 基于贝塞尔曲线的四足机器人运动控制方法


2.1 引言

在使用强化学习对机器人进行控制时,由于机器人的运动和观测空间较大,学习过程中面临着广阔的搜索空间。特别是在任务困难且场景复杂的情况下,可能会出现稀疏奖励等问题。因此,近年来越来越多的学者开始关注基于中枢模式发生器 (Central Pattern Generator, CPG)^[44]或运动轨迹辅助^[46]的强化学习方法。这些方法可以在一定程度上减少搜索空间、并减轻端到端强化学习中的超调现象,降低对电机的损害风险。其中,基于贝塞尔曲线的运动控制方法^[59]以其平滑性、连续性和局部控制性等优点,在机器人的轨迹控制方面得到了广泛的应用。由于在研究机器人控制方法之前,了解机器人的运动学建模是必要的。因此,本章首先对实验所采用的机器鼠 NeRmo Lite^[2]的腿部正逆向运动建模和足端运动空间进行了分析,并在此基础上介绍了基于贝塞尔曲线的机器人运动控制方法。


2.2 机器人运动学建模

本文所使用的机器鼠具有 12 个自由度,其中四条腿分别包含两个自由度。鉴于本文的重点是四足机器人的运动状况,因此本文在实际控制中仅对四条腿的 8 个自由度进行控制。为了实现对机器人的控制,完善的运动学分析和建模是必不可少的。四足机器人的运动学分析主要包括正运动学(将电机转动角度映射到腿部末端点坐标)和逆运动学(将腿部末端点坐标映射到电机转动角度)分析。这些分析将为后文中基于建模计算和基于强化学习控制方法的研究提供基础支持。


机器鼠 NeRmo 具有两条前腿和两条后腿,其结构分别相同,如图2.1所示。机器鼠的腿部采用绳驱动结构。在左右腿的抽象几何图中,已知信息包括:两电机间的距离 $|OE|$ 、E 点处电机的半径 r_p 、 $|OB|$ 初始长度(即电机均位于初始位置时) l_{r0} ,以及腿部各部分 $|OA||AB||BC||CD| \angle DCA$ 已知且恒定。此外,虽然红线处的绳长未知,但可以假设绳子长度不会因受力大小而改变。通过下面的推导证明可以发现,绳子长度不会对电机角度与腿部末端点之间的映射产生影响。在点 O 处建立了一个沿着 yz 平面的直角坐标系。接下来,本文将分别在正向和逆向运动学分析中建立电机转动角度 (q_1, q_2) 即 $(\angle GOA, \angle IEH)$ 与腿部末端点位置 (y, z) 之间的关系。之间的关系。由于前后腿几何结构接近,为了防止内容冗余下面只对前



(a) 机器鼠前后腿结构示意图



(b) 机器鼠左腿几何结构



(c) 机器鼠右腿几何结构

图 2.1 机器鼠腿部结构：其中 OE 两点是电机位置、D 点为腿部末端点位置，红线代表绳子。

腿进行运动学分析，后腿的分析方法与前腿相同。

2.2.1 腿部正运动学分析

对于前腿

$$\begin{aligned} \overline{HI} &= r_p \cdot q_2 \\ |OB| &= l_{r0} + \overline{HI} \end{aligned} \quad (2.1)$$

在 $\triangle AOB$ 中，通过余弦定理可求得

$$\begin{aligned}\angle AOB &= \arccos\left(\frac{|AO|^2 + |BO|^2 - |AB|^2}{2|AO||BO|}\right) \\ \angle OAB &= \arccos\left(\frac{|AO|^2 + |AB|^2 - |OB|^2}{2|AO||AB|}\right)\end{aligned}\quad (2.2)$$

在 $\triangle DCA$ 中，通过余弦定理可求得

$$\begin{aligned}|DA| &= \sqrt{|DC|^2 + |AC|^2 - 2|DC||AC|\cos(\angle DAC)} \\ \angle DAC &= \arccos\left(\frac{|DA|^2 + |AC|^2 - |DC|^2}{2|DA||AC|}\right)\end{aligned}\quad (2.3)$$

在 $\triangle DAO$ 中，通过余弦定理可求得

$$\begin{aligned}\angle DAO &= \angle BAO - \angle DAC \\ |DO| &= \sqrt{|DA|^2 + |AO|^2 - 2|DA||AO|\cos(\angle DAO)} \\ \angle DOA &= \arccos\left(\frac{|DO|^2 + |OA|^2 - |AD|^2}{2|DO||OA|}\right)\end{aligned}\quad (2.4)$$

于是可求得 D 点坐标

$$\begin{aligned}\angle DOG &= \angle DOA - q_1 \\ D = (y, z) &= (-|OD|\sin(\angle DOG), -|OD|\cos(\angle DOG))\end{aligned}\quad (2.5)$$

綜上前腿的正向运动建模完毕。

2.2.2 腿部逆运动学分析

对于前腿有

$$\begin{aligned}|DO| &= \sqrt{y^2 + z^2} \\ \angle DOG &= \arctan\left(\frac{y}{z}\right)\end{aligned}\quad (2.6)$$

根据公式2.3可以求得 $|DA|$ 和 $\angle DAC$ ，于是在 $\triangle DOA$ 中根据余弦定理

$$\angle OAD = \arccos\left(\frac{|DO|^2 + |OA|^2 - |AD|^2}{2|DO||OA|}\right)\quad (2.7)$$

于是在 $\triangle ABO$ 中根据余弦定理

$$\begin{aligned}\angle OAB &= \angle OAD + \angle DAC \\ |OB| &= \sqrt{|OA|^2 + |AB|^2 - 2|OA||AB|\cos(\angle OAB)} \\ \angle AOB &= \arccos\left(\frac{|AO|^2 + |OB|^2 - |AB|^2}{2|AO||OB|}\right)\end{aligned}\quad (2.8)$$

由公式2.1可知

$$\begin{aligned}\widehat{HI} &= l_{r_0} - |OB| \\ q_2 &= \frac{\widehat{HI}}{r_p}\end{aligned}\quad (2.9)$$

由角度关系可得

$$q_1 = \angle DOA - \angle DOG \quad (2.10)$$

綜上前腿的逆向运动建模完毕。

2.2.3 足端工作空间




图 2.2 机器鼠足端工作空间

足端工作空间是指在满足特定约束条件的前提下，机器鼠腿部末端点可以到达的所有位置的集合。了解机器鼠的足端工作空间对于有效控制机器鼠非常重要。特别是在进行逆向运动建模时，如果足端位置设置不合理，可能会导致超调现象或使电机转动角度超出安全范围，从而损坏机器鼠。对于本实验中的机器鼠，腿部所有电机的转动范围都限定在 $[-\pi/2, \pi/2]$ 之间。机器鼠前后腿在正常工作时能够达到的空间位置范围如图2.2所示。

2.3 贝塞尔曲线

贝塞尔曲线是一种由一系列控制点 $P = [P_1, P_2, \dots, P_n]$ 确定的光滑曲线，其中控制点的个数 n 被称为贝塞尔曲线的阶数，其数学表达式如下所示：

$$B(t) = \sum_{i=0}^n P_i B_{i,n}(t), \quad 0 \leq t \leq 1 \quad (2.11)$$

$$B_{i,n}(t) = C_n^i (1-t)^{n-i} t^i$$

其中 $B_{i,n}$ 被称为贝塞尔曲线的第 i 个系数， C_n^i 表示组合数。

贝塞尔曲线具有许多特殊的性质使得它在机器人运动轨迹规划中得到了广泛的应用，例如：

(1) 贝塞尔曲线经过控制点 P_0 与 P_n ：

$$B(0) = P_0$$

$$B(1) = P_n \quad (2.12)$$

(2) 贝塞尔曲线的 m 阶导数具有以下性质：

$$B^{(m)}(t) = \frac{n!}{(n-m)!} \sum_{i=0}^{n-m} P_i^{(m)} B_{i,n-m}(t) \quad (2.13)$$

$$P_i^{(m)} = P_{i+1}^{(m-1)} - P_i^{(m-1)}$$

其中 $P_i^{(m)}$ 表示 P_i 的 m 阶前项差分。通过第一数学归纳法可以证明这一性质：

a. 当 $m = 0$ 时

$$B^{(0)}(t) = B(t)$$

$$\frac{n!}{(n-0)!} \sum_{i=0}^{n-0} P_i^{(0)} B_{i,n-0}(t) = \sum_{i=0}^n P_i B_{i,n}(t) \quad (2.14)$$

根据式 (2.11)，上述两项是相等的。

b. 假设 $m = k$ 时公式2.13成立：

$$B^{(k)}(t) = \frac{n!}{(n-k)!} \sum_{i=0}^{n-k} P_i^{(k)} B_{i,n-k}(t) \quad (2.15)$$

则当 $m = k + 1$ 时:

$$\begin{aligned}
 B^{(k+1)}(t) &= \frac{dB^{(k)}(t)}{dt} \\
 &= \frac{n!}{(n-k)!} \sum_{i=0}^{n-k} P_i^{(k)} \frac{d(C_{n-k}^i (1-t)^{n-k-i} t^i)}{dt} \\
 &= \frac{n!}{(n-k)!} \{-P_0^{(k)} C_{n-k}^0 (n-k)(1-t)^{n-k-1} \\
 &\quad + \sum_{i=1}^{n-k-1} C_{n-k}^i [-(n-k-i)(1-t)^{n-k-i-1} t^i + i(1-t)^{n-k-i} t^{i-1}] P_i^{(k)} + P_{n-k}^{(k)} C_{n-k}^{n-k} (n-k) t^{n-k-1}\} \\
 &= \frac{n!}{(n-k)!} (n-k) \{-P_0^{(k)} (1-t)^{n-k-1} \\
 &\quad + \sum_{i=1}^{n-k-1} [-C_{n-k-1}^i (1-t)^{n-k-i-1} t^i + C_{n-k-1}^{i-1} (1-t)^{n-k-i} t^{i-1}] P_i^{(k)} + P_{n-k}^{(k)} t^{n-k-1}\} \\
 &= \frac{n!}{[n-(k+1)]!} [-P_0^{(k)} (1-t)^{n-k-1} - \sum_{i=1}^{n-k-1} C_{n-k-1}^i (1-t)^{n-k-i-1} t^i P_i^{(k)} \\
 &\quad + \sum_{i=1}^{n-k-1} C_{n-k-1}^{i-1} (1-t)^{n-k-i} t^{i-1} P_i^{(k)} + P_{n-k}^{(k)} t^{n-k-1}] \\
 &= \frac{n!}{[n-(k+1)]!} [-C_{n-(k+1)}^0 (1-t)^{n-(k+1)-0} t^0 - \sum_{i=1}^{n-(k+1)} C_{n-(k+1)}^i (1-t)^{n-(k+1)-i} t^i P_i^{(k)} \\
 &\quad + \sum_{i=0}^{n-(k+1)-1} C_{n-(k+1)}^i (1-t)^{n-(k+1)-i} t^i P_{i+1}^{(k)} + C_{n-(k+1)}^{n-(k+1)} P_{n-(k+1)+1}^{(k)} t^{n-(k+1)}] \\
 &= \frac{n!}{[n-(k+1)]!} [-\sum_{i=0}^{n-(k+1)} C_{n-(k+1)}^i (1-t)^{n-(k+1)-i} t^i P_i^{(k)} + \sum_{i=0}^{n-(k+1)} C_{n-(k+1)}^i (1-t)^{n-(k+1)-i} t^i P_{i+1}^{(k)}] \\
 &= \frac{n!}{[n-(k+1)]!} \sum_{i=0}^{n-(k+1)} C_{n-(k+1)}^i (1-t)^{n-(k+1)-i} t^i (P_{i+1}^{(k)} - P_i^{(k)}) \\
 &= \frac{n!}{[n-(k+1)]!} \sum_{i=0}^{n-(k+1)} C_{n-(k+1)}^i (1-t)^{n-(k+1)-i} t^i P_i^{(k+1)} \\
 &= \frac{n!}{[n-(k+1)]!} \sum_{i=0}^{n-(k+1)} P_i^{(k+1)} B_{i,n-(k+1)}(t)
 \end{aligned} \tag{2.16}$$

因此, 根据第一数学归纳法可以证明公式 (2.13) 对于所有整数 $m (m \leq n)$ 成立。

(3) 由性质 (2) 还可得到以下公式:

$$\begin{aligned}
 B^{(m)}(0) &= P_0^{(m)} \\
 B^{(m)}(1) &= P_{n-m}^{(m)}
 \end{aligned} \tag{2.17}$$

贝塞尔曲线的这些特性使其在计算机图形学和运动规划领域得到广泛应用。通过适当选择控制点和阶数，可以创建各种曲线形状，从简单的直线和二次曲线到更复杂的形状。在机器人运动规划中，贝塞尔曲线常用于描述平滑的运动轨迹，例如机械臂的轨迹规划和路径规划等应用场景。通过合理设置控制点，可以规划运动过程中不同位置的速度和加速度。这种能力使得贝塞尔曲线成为控制机器人运动的重要工具，能够确保运动轨迹的平滑和连续性。

2.4 基于贝塞尔曲线的运动轨迹生成器

基于贝塞尔曲线的机器人运动轨迹生成器可以通过以下公式表示：

$$B(S(t)) = \sum_{i=0}^n P_i B_{i,n}(S(t)) \quad (2.18)$$

其中， $S(t) \in [0, 1]$ 表示机器人的摆动信号， t 表示时间。通过该公式可以计算出速度和加速度：

$$\begin{aligned} v(t) &= \frac{dB(S(t))}{dt} = \frac{dB(S)}{dS} \frac{dS}{dt} \\ a(t) &= \frac{d^2B(S(t))}{dt^2} = \frac{dB(S)}{dS} \frac{d^2S}{dt^2} + \frac{d^2B(S)}{dS^2} \left(\frac{dS}{dt}\right)^2 \end{aligned} \quad (2.19)$$

根据公式2.17可知，当 $S(t) = 0$ 时

$$\begin{aligned} B(S(t)) &= P_0 \\ v(t) &= nP_0^{(1)} = n(P_1 - P_0) \frac{dS}{dt} \Big|_{S=0} \end{aligned} \quad (2.20)$$

当 $S(t) = 1$ 时

$$\begin{aligned} B(S(t)) &= P_n \\ v(t) &= P_{n-1}^{(1)} = n(P_n - P_{n-1}) \frac{dS}{dt} \Big|_{S=1} \end{aligned} \quad (2.21)$$

这些性质对于设计机器人的贝塞尔运动轨迹具有重要的指导作用。例如：

(1) 运动轨迹会经过控制点 P_0 和 P_n 。

(2) 当 $S(t) = 0$ 时，速度与 $\overrightarrow{P_0P_1}$ 成正比、在 $\overrightarrow{P_0P_1}$ 的垂直方向速度为 0。当 $S(t) = 1$ 时，速度与 $\overrightarrow{P_{n-1}P_n}$ 成正比、在 $\overrightarrow{P_{n-1}P_n}$ 的垂直方向速度为 0。

目前最经典的四足机器人贝塞尔曲线轨迹由 Hyun 等人^[59]提出。他们根据贝塞尔曲线的性质，并结合机器人腿部在不同区域的运动特点，设计了适用于四足

机器人的贝塞尔曲线控制点。

首先，机器人的摆动信号可以如下定义：

$$S(t) = \Delta S + \begin{cases} \frac{t + \hat{T}_{sw}}{\hat{T}_{sw}}, & -\hat{T}_{sw} < t < 0 \\ \frac{t}{\hat{T}_{st}}, & 0 < t < \hat{T}_{st} \\ \frac{t - \hat{T}_{st}}{\hat{T}_{sw}}, & \hat{T}_{st} < t < \hat{T}_{st} + \hat{T}_{sw} \end{cases} \quad (2.22)$$

其中， ΔS 表示四条腿的相位差。在文章^[59]中，慢走和快走两种状态下的相位差分别被定义为： $\Delta S_{trot} = [0, 0.5, 0.5, 0]^T$ 和 $\Delta S_{gallop} = [0, 0.75, 0.35, 0.1]^T$ 。 $\hat{T}_{sw}$ 和 $\hat{T}_{st}$ 分别是机器人腿部的站立和摆动周期。当 $0 < t < \hat{T}_{st}$ 时，机器人腿部与地面接触；而 $-\hat{T}_{sw} < t < 0$ 和 $\hat{T}_{st} < t < \hat{T}_{st} + \hat{T}_{sw}$ 分别代表机器人抬腿和落腿的时期。摆动周期 T_{sw} 在文献^[60]中被设定为恒定值，而站立周期 $\hat{T}_{st}$ 则根据以下公式确定：

$$v_d = \frac{2L_{span}}{\hat{T}_{st}} \quad (2.23)$$

其中， v_d 表示期望的运动速度， L_{span} 表示每条腿每次前进距离的一半。

在站立周期内，腿部的运动轨迹参考了自然界中四足动物的运动方式，并采用动力学的设计方法，如图2.3下半部分所示，表达如下：

$$\begin{aligned} X &= \tau(1 - 2S(t)) \\ Y &= \delta \cos \frac{\pi(1 - 2S(t))}{2} \end{aligned} \quad (2.24)$$

其中， τ 和 δ 为参数。

表 2.1 贝塞尔曲线控制点：其中 τ 和 ψ 为参数

控制点	坐标	控制点	坐标
P_0	$(-\tau, 0)$	P_7	$(0, 1.1\psi)$
P_1	$(-1.4\tau, 0)$	P_8, P_9	$(1.5\tau, 1.1\psi)$
P_2, P_3, P_4	$(-1.5\tau, 0.9\psi)$	P_{10}	$(1.4\tau, 0)$
P_5, P_6	$(0, 0.9\psi)$	P_{11}	$(\tau, 0)$

而在摆动周期内，腿部运动的轨迹是一条贝塞尔曲线，该曲线由 12 个控制点生成，如表格2.1和图2.3上半部分所示。控制点的设计思路如下：

(1) 第一个控制点 P_0 和最后一个控制点 P_{11} 的纵坐标为 0，确保了运动轨迹起止位置都恰好在地面上。

(2) 前两个控制点 P_0 和 P_1 的纵坐标相同，最后两个控制点 P_{10} 和 P_{11} 的纵坐




图 2.3 基于贝塞尔曲线的机器人腿部运动轨迹

标相同，保证了起止位置在垂直方向上的速度为 0（参考公式 2.20 和 2.21）。

(3) $P_2 \sim P_4$ 三个控制点重合， $P_8 \sim P_9$ 两个控制点重合，用于改变力的方向，调整腿部运动轨迹的方向。

(4) $P_5 \sim P_7$ 的横坐标相同， $P_7 \sim P_9$ 的纵坐标相同，分别对曲线起到纵向和横向的牵引效果。

然而，本文注意到文章^[59]在建模贝塞尔轨迹控制方法的推断中存在一定不足之处：“两个重叠的控制点会导致 0 速度，三个重叠的控制点会导致 0 加速度”。下面通过反例进行证明：

以三个控制点的贝塞尔曲线为例：

$$\begin{aligned}
 v(t) &= \frac{dS}{dt} 3 \sum_{i=0}^2 P_i^{(1)} B_{i,2}(S) \\
 &= 3 \frac{dS}{dt} \sum_{i=0}^2 (P_{i+1} - P_i) C_2^i (1-S)^{2-i} S^i \\
 &= 3 \frac{dS}{dt} [(P_3 - P_2)S^2 + 2(P_2 - P_1)(1-S)S + (P_1 - P_0)(1-S)^2] \\
 &= 3 \frac{dS}{dt} [(P_3 - 3P_2 + 3P_1 - P_0)S^2 + (2P_2 - 4P_1 + 2P_0)S + (P_1 - P_0)]
 \end{aligned} \tag{2.25}$$

假设存在两个重合点 P_1 和 P_2 ，并且 $P_3 > P_2 = P_1 > P_0$ ，则有：

$$v(t) = 3 \frac{dS}{dt} [(P_3 - P_0)S^2 + (2P_0 - 2P_1)S + (P_1 - P_0)] \tag{2.26}$$

根据上文对 $S(t)$ 的设置， $\frac{dS}{dt}$ 为常数。因此，若存在 $S \in [0, 1]$ 使得 $v(t) = 0$ ，则必须满足 $(P_3 - P_0)S^2 + (2P_0 - 2P_1)S + (P_1 - P_0) = 0$ 。由于 $P_3 - P_0 > 0$ ，因此

$(P_3 - P_0)S^2 + (2P_0 - 2P_1)S + (P_1 - P_0)$ 是一个开口向上的二次函数, 在 $S = \frac{P_1 - P_0}{P_3 - P_0}$ 处取得最小值。同时, 由于 $P_3 > P_1 > P_0$, 所以 $0 < \frac{P_1 - P_0}{P_3 - P_0} < 1$ 。因此, 在 $S \in [0, 1]$ 范围内, $(P_3 - P_0)S^2 + (2P_0 - 2P_1)S + (P_1 - P_0)$ 的最小值将在 $S = \frac{P_1 - P_0}{P_3 - P_0}$ 处取得。此时有:

$$\begin{aligned}
 & \min\{(P_3 - P_0)S^2 + (2P_0 - 2P_1)S + (P_1 - P_0)\} \\
 &= (P_3 - P_0)\left(\frac{P_1 - P_0}{P_3 - P_0}\right)^2 + (2P_0 - 2P_1)\frac{P_1 - P_0}{P_3 - P_0} + (P_1 - P_0) \\
 &= \frac{(P_1 - P_0)^2 - 2(P_1 - P_0)^2 + (P_1 - P_0)(P_3 - P_0)}{P_3 - P_0} \\
 &= \frac{(P_1 - P_0)(P_3 - P_0 - P_1 + P_0)}{P_3 - P_0} = \frac{(P_1 - P_0)(P_3 - P_1)}{P_3 - P_0}
 \end{aligned} \tag{2.27}$$

由于 $P_3 > P_1 > P_0$, $(P_1 - P_0)$, $(P_3 - P_1)$, $(P_3 - P_0)$ 都是正数, 因此可以得出结论: $\min\{(P_3 - P_0)S^2 + (2P_0 - 2P_1)S + (P_1 - P_0)\} > 0$, 即不存在使 $v(t) = 0$ 的 S 。因此, 两个重叠的控制点并不能保证产生 0 速度。

同时, 在当前的设置中 $\frac{dS}{dt}$ 为常数, 因此 $\frac{d^2S}{dt^2} = 0$, 可以得到以下推导:

$$a(t) = 0 + \frac{d^2B(S)}{dS^2}\left(\frac{d^2S}{dt^2}\right)^2 = \left(\frac{d^2S}{dt^2}\right)^2 n(n-1) \sum_{i=0}^{n-2} P_i^{(2)} B_{i,n-2}(t) \tag{2.28}$$

这里以具有四个控制点的贝塞尔曲线为例进行说明:

$$\begin{aligned}
 a(t) &= 12\left(\frac{d^2S}{dt^2}\right)^2 \sum_{i=0}^2 P_i^{(2)} B_{i,2}(t) \\
 &= 12\left(\frac{d^2S}{dt^2}\right)^2 [(P_3^{(1)} - 3P_2^{(1)} + 3P_1^{(1)} - P_0^{(1)})S^2 + (2P_2^{(1)} - 4P_1^{(1)} + 2P_0^{(1)})S + (P_1^{(1)} - P_0^{(1)})]
 \end{aligned} \tag{2.29}$$

假设重合的三个控制点为 P_1, P_2, P_3 , 则 $P_1^{(1)} = P_2 - P_1 = 0$, $P_2^{(1)} = P_3 - P_2 = 0$ 。因此可以简化上述表达式为:

$$a(t) = 12\left(\frac{d^2S}{dt^2}\right)^2 [(P_3^{(1)} - P_0^{(1)})S^2 + 2P_0^{(1)}S - P_0^{(1)}] \tag{2.30}$$

假设 $P_4 > P_0 > P_1 = P_2 = P_3$, 则 $(P_3^{(1)} - P_0^{(1)}) = P_4 - P_3 - P_1 + P_0 > P_4 - P_0 > 0$, 因此 $(P_3^{(1)} - P_0^{(1)})S^2 + 2P_0^{(1)}S - P_0^{(1)}$ 表示一个开口朝上的二次曲线。当 $S = \frac{P_0^{(1)}}{P_0^{(1)} - P_3^{(1)}} = \frac{P_0 - P_1}{P_4 - P_3 - P_1 + P_0}$ 时, 该二次曲线取得最小值。并且, $0 < \frac{P_0 - P_1}{P_4 - P_3 - P_1 + P_0} < \frac{P_0 - P_1}{P_0 - P_3 - P_1 + P_0} = \frac{P_0 - P_1}{2(P_0 - P_1)} = \frac{1}{2}$ 。因此, $(P_3^{(1)} - P_0^{(1)})S^2 + 2P_0^{(1)}S - P_0^{(1)}$ 在 $S \in [0, 1]$ 范围内的最小值将

在 $S = \frac{P_0^{(1)}}{P_0^{(1)} - P_3^{(1)}}$ 处取得。此时，最小值为：

$$\begin{aligned}
 & \min\{(P_3^{(1)} - P_0^{(1)})S^2 + 2P_0^{(1)}S - P_0^{(1)}\} \\
 &= (P_3^{(1)} - P_0^{(1)})\left(\frac{P_0^{(1)}}{P_0^{(1)} - P_3^{(1)}}\right)^2 + 2P_0^{(1)}\frac{P_0^{(1)}}{P_0^{(1)} - P_3^{(1)}} - P_0^{(1)} \\
 &= \frac{-(P_0^{(1)})^2 + 2(P_0^{(1)})^2 - P_0^{(1)}(P_0^{(1)} - P_3^{(1)})}{P_0^{(1)} - P_3^{(1)}} \\
 &= \frac{-P_0^{(1)}P_3^{(1)}}{-P_0^{(1)} + P_3^{(1)}} = \frac{(P_0 - P_1)(P_4 - P_3)}{P_4 - P_3 - P_1 + P_0}
 \end{aligned} \tag{2.31}$$

由于 $P_4 > P_0 > P_1 = P_2 = P_3$, $(P_0 - P_1)$, $(P_4 - P_3)$, $(P_4 - P_3 - P_1 + P_0)$ 都是正数。因此, $\min\{(P_3^{(1)} - P_0^{(1)})S^2 + 2P_0^{(1)}S - P_0^{(1)}\} > 0$, 所以不存在使得 $a(t) = 0$ 的 S 。

虽然“两个重叠的控制点会导致速度为零, 三个重叠的控制点会导致加速度为零”这一说法并不正确, 然而当存在多个控制点重合或多个控制点共线时, 会对轨迹产生一定的牵引作用。

2.5 本章小结

本章首先对机器鼠的腿部进行了正向和逆向运动学推导, 并展示了足端工作空间。这些内容为后续的建模控制和强化学习控制方法奠定了基础。接着介绍了贝塞尔曲线的基本性质, 详细阐述了基于贝塞尔曲线设计机器人腿部运动轨迹的思路。在第4章中通过实验展示了这种方法在机器鼠上的应用效果, 然而实验结果表明, 尽管基于贝塞尔曲线的运动策略在平坦地面上表现良好, 但在存在障碍物的场景中, 机器鼠很难前进。因此在下一章节中, 我们将采用强化学习方法对基于贝塞尔曲线的运动策略进行改进, 以使其适应多种不同的场景要求。

3 轨迹调制辅助的强化学习四足机器人运动控制方法

3.1 引言

为了解决上一章提出的基于建模计算的方法在面对不同场景时需要设计不同控制方法的问题，本章采用强化学习的方法来设计机器人的运动控制策略。为了更好地将强化学习应用于小型机器人，本章首先采用了轻量级的 ARS 算法来设计强化学习框架。随后为了提升模型的性能，本文将 ARS 方法与贝塞尔曲线结合，提出了 ARS-Bezier 方法，使得机器人能够更容易地从环境中学习到适合的运动策略。最后，为了使学到的策略具有更好的迁移性，本文还设计了环境随机化的方法，在训练过程中让机器人在各种随机生成的凹凸不平的地形中学会前进的策略，从而使机器人能够应对各种复杂障碍。

3.2 强化学习概述

目前的机器学习主要分为监督学习、无监督学习和强化学习三类^[61]，尽管这三类方法在某些方面存在差异，但它们也存在一些相互交叉的共同点。在机器人运动控制中，强化学习是最常用的方法之一。它通过智能体与环境之间的交互来学习适应不同情境下的步态动作。相比传统的基于模型的控制方法，强化学习具有更高的灵活性和对不同地形的适应性。最近，随着模仿学习和元学习等概念的引入，监督学习和无监督学习也逐渐被应用于机器人控制领域^[62-63]。

强化学习以马尔可夫决策过程为基本框架，其中最重要的元素是状态空间、动作空间和奖励函数。强化学习的目标是根据当前状态进行动作决策，以获得最大的长期奖励。强化学习的马尔可夫决策过程可以表示为五元组 (S, A, R, P, γ) 。其中， $S \in \mathbb{R}^n$ 和 $A \in \mathbb{R}^m$ 分别表示状态空间和动作空间， $R: S \times A \rightarrow \mathbb{R}^1$ 表示奖励函数， $P: S \times A \rightarrow S'$ 表示状态转移概率矩阵， $\gamma \in [0, 1]$ 表示奖励的折扣因子。

具体来说，本文中强化学习的目标是学习决策函数 $\pi(\theta)$ 的最优参数 θ^* 。对于每个状态 $s \in S$ ，通过决策函数选择最优的动作 $a \sim \pi(a_i|s, \theta)$ ，然后执行该动作与环境进行交互，得到奖励值 $r = R(s, a)$ 。通过状态转移概率矩阵，得到下一步的状态 $s' \sim P(s_i|s, a)$ 。由于强化学习被抽象为马尔可夫决策过程，因此每一步的状态转移只与当前步的状态和动作有关，即 $P(s(t)|s(t-1), a(t-1)) = P(s(t)|s(t-1), a(t-1), s(t-2), a(t-2), \dots, s(0), a(0))$ 。强化学习的目标是求解公

式3.1所示的优化问题：

$$\begin{aligned}\theta^* &= \operatorname{argmax}(\sum_{t=0}^T \gamma^t r_t) \\ r_t &= R(\tau_t) \\ \tau_t &= s_0, a_0, s_1, a_1, \dots, s_T, a_T\end{aligned}\tag{3.1}$$

其中， r_t 代表第 t 步的奖励值， τ 代表交互过程中产生的状态-动作轨迹。当折扣因子 γ 接近 1 时，智能体更关注长期奖励；当 γ 接近 0 时，智能体更关注即时奖励。

3.3 基于 ARS 算法的强化学习方法

近年来随着深度学习的发展，传统的强化学习方法通常涉及神经网络的训练，同时许多强大有效的深度强化学习方法也随之出现。然而这些方法在训练过程中通常需要较大的计算开销，甚至需要大量的 GPU 资源。此外很多方法还依赖于较大的观测空间。然而对于计算能力有限、传感器有限的小型机器人，这些方法是不可行的。即使可以在大型服务器上通过仿真方法进行训练，由于仿真环境和真实环境之间无法完全避免的差异，大部分方法仍需要在真实机器人上进行微调，因此算法必须考虑到实际机器人可用的资源。尽管诸如 Proximal Policy Optimization (PPO)^[34]、Trust Region Policy Optimization (TPRO)^[64] 等算法可以加快训练速度并减少训练开销，但仍无法满足小型机器人的需求。因此，基础型随机搜索算法 (Basic Random Search, BRS)、增强型随机搜索算法 (Augmented Random Search, ARS)^[58] 等随机搜索算法凭借其计算开销小的优点，在小型机器人上取得了显著的效果。

ARS 算法由 Mania 等人在 2018 年左右提出，通过对传统的 BRS 算法进行改进，显著提高了模型的性能，同时保持了较低的计算成本和较快的训练速度，这使得 ARS 算法能够在强化学习中达到许多神经网络的性能水平。图3.1展示了 ARS 和 BRS 算法的流程图，不同变体的 ARS 在流程框中用不同的颜色表示。具体而言，ARS 包括两个版本：ARS-v1 和 ARS-v2，并且可以进一步添加 ARS-top 形成 ARS-v1-t 和 ARS-v2-t。

BRS 算法使用简单的随机采样方法，使得待优化参数 θ 在每一轮迭代中朝着奖励函数值增大的方向移动。然而，BRS 算法存在训练不稳定、难以收敛或难以跳出局部最优值等问题，为了解决这些问题，ARS 算法进行了几项改进。

首先，在一般的强化学习中，随着模型训练的进行，奖励函数值逐渐增加，这




图 3.1 ARS 与 BRS 算法流程图：其中黑色框代表各方法的相同的步骤，蓝色、绿色、红色、紫色框分别表示 ARS-v1、ARS-v2、ARS-top、BRS 算法特有的步骤

可能导致更新步长即 $\sum_i (r(\pi_{\theta+\delta_i}) - r(\pi_{\theta-\delta_i}))\delta_i$ 逐渐增大，随着训练轮数的增加参数波动变大，导致模型难以收敛。为了保持更新步长的稳定性，ARS-v1 算法通过将更新步长除以其标准差来进行标准化。另外许多神经网络通过对输入数据进行正则化，例如批归一化（Batch-Norm）、层归一化（Layer-Norm）、余弦归一化（Cos-Norm）等操作解决输入数据内部协变量偏移的问题，进而缓解反向传播中梯度爆炸或梯度消失等问题。在传统的 BRS 算法中，尽管策略函数 π 可以是简单的线性函数而无需激活层，但协变量偏移问题仍然可能导致模型难以收敛。这是因为随着模型训练的进行，智能体在环境中观测到的状态空间会发生很大的变化，导致训练初期的策略函数 π 在后期的状态空间下不适用。为了解决这个问题，ARS-v2 算法通过归一化操作很好地缓解了协变量偏移问题，并且采用了神经网络中的移动平均策略来不断更新归一化函数中的均值和方差，以确保输入的不同维度仍然

包含各自的相关信息。

此外,为了进一步解决 BRS 算法训练过程的不稳定性,ARS-top 算法通过选择具有最大 $|r(\pi_{\theta+\delta_i}) - r(\pi_{\theta-\delta_i})|$ 的 b 组样本进行参数更新。这是因为如果 $|r(\pi_{\theta+\delta_i}) - r(\pi_{\theta-\delta_i})|$ 较小,很可能表示在 θ 朝 δ_i 方向上的更新对奖励函数的增加没有帮助,反而可能对模型性能产生负面影响。

在机器鼠 NeRmo^[2]上,简单的 ARS 算法已经取得了较好的效果。本文参考了过往的工作^[65],设计了强化学习的状态空间、动作空间和奖励函数,并且使用 ARS-v2-top 作为训练优化方法。

(1) 状态空间: 机器鼠的观测空间包括各传感器的值以及每步的动作和奖励函数值。在本文中采用的状态空间如公式3.2所示:

$$s_t = (a_{t-1}, r_{t-1} \in R, \vec{V}_{vel} \in R^3, \vec{V}_{gyro} \in R^3, \vec{V}_Q \in R^4, \mathbf{c}_F \in R^4) \quad (3.2)$$

其中,各符号的含义依次为上一时刻的动作、上一时刻的奖励函数值、三维线速度、三维角速度、表示机器人朝向的四元数,以及四条腿的压力传感器读数。之所以使用速度而不是加速度作为状态空间的一部分,是因为通过实验发现使用速度值可以使机器人更好地学习运动策略。

(2) 动作空间: 对于纯 ARS 控制方法,本文设计了两种不同的动作空间。这两种动作空间都包含八个不同的维度,即 $a \in R^8$ 。第一种方法是端对端的控制方法,称为 ARS-end,动作空间为四条腿八个电机的转动角度,如公式3.3所示:

$$a^{end} = (q_1^{fl}, q_2^{fl}, q_1^{fr}, q_2^{fr}, q_1^{rl}, q_2^{rl}, q_1^{rr}, q_2^{rr}) \quad (3.3)$$

第二种方法则是将四条腿的末端点位置设为动作空间,称为 ARS-pos。许多论文^[66-67,29]都提到,端对端方法通常需要更多的样本和训练时间,而且在实际应用中可能面临时间和计算资源的限制。将实际空间中的位置设为动作空间可能会带来更好的学习效果。当获取腿部末端点的位置后,可以通过逆运动学的方法将其转换为电机的转动角度,从而实现对机器人的控制,如公式3.4所示:

$$a^{pos} = (x^{fl}, y^{fl}, x^{fr}, y^{fr}, x^{rl}, y^{rl}, x^{rr}, y^{rr}) \quad (3.4)$$

(3) 奖励函数: 强化学习的目标是最大化长期奖励函数,因此奖励函数的设计对算法的性能有很大影响。较差的奖励函数可能导致稀疏奖励等问题,使智能体难以学习到合适的策略。本文设计的奖励函数定义如下:

$$r = \begin{cases} W_{vel} \vec{V}_{vel} \cdot \vec{u}_{dir}, & \vec{V}_{vel} \cdot \vec{u}_{dir} < T_{vel} \\ -r_p, & \vec{V}_{vel} \cdot \vec{u}_{dir} \geq T_{vel} \end{cases} \quad (3.5)$$

其中, $\vec{u}_{dir}$ 代表机器人的前进方向, W_{vel} 是奖励函数的系数, T_{vel} 代表前进方向速度的阈值。设置这个阈值的原因是, 如果速度过大, 可能会导致机器人跌倒。如果机器人跌倒的概率很大, 可能会导致奖励函数值长期偏低, 进而使参数陷入局部最优点。因此, 当速度高于阈值时, 需要添加惩罚 $-r_p (r_p > 0)$ 。

(4) 策略函数: 本文的 ARS 算法采用的策略函数如公式3.6所示, 可以看作是单层感知机。首先, 将输入进行归一化以防止协变量偏移, 然后经过一个线性层, 最后使用 Tanh 作为激活函数。这里使用激活函数的目的是将输出映射到 $[-1, 1]$ 之间, 符合动作空间的范围。

$$\begin{aligned} \pi_{\theta}(x) &= \text{Tanh}(\theta^T \text{Norm}(x)) \\ \text{Tanh}(x) &= 1 - \frac{2}{e^{2x} + 1} \\ \text{Norm}(x_i) &= \frac{x_i - \mu_i}{\delta_i} \end{aligned} \quad (3.6)$$

其中, 正则化中的参数均值与标准差 μ, δ 分别采用如公式3.7和3.8中的迭代方法不断更新

$$\begin{aligned} \mu_i^{(j)} &= \frac{1}{iN} \sum_{m=1}^i \sum_{k=1}^N x_{m,k}^{(j)} \\ &= \frac{1}{iN} [(i-1)N\mu_{i-1}^{(j)} + \sum_{k=1}^N x_{i,k}^{(j)}] \\ &= \mu_{i-1}^{(j)} + \frac{1}{i} \left(\frac{1}{N} \sum_{k=1}^N x_{i,k}^{(j)} - \mu_{i-1}^{(j)} \right) \end{aligned} \quad (3.7)$$

$$\begin{aligned}
 \delta_i^{(j)} &= \sqrt{\frac{1}{iN} \sum_{m=1}^i \sum_{k=1}^N (x_{m,k}^{(j)} - \mu_i^{(j)})^2} \\
 &= \sqrt{\frac{1}{iN} \sum_{m=1}^i \sum_{k=1}^N (x_{m,k}^{(j)} - \mu_{i-1}^{(j)} + \mu_{i-1}^{(j)} - \mu_i^{(j)})^2} \\
 &= \sqrt{\frac{1}{iN} \sum_{m=1}^i \sum_{k=1}^N [(x_{m,k}^{(j)} - \mu_{i-1}^{(j)})^2 + (\mu_{i-1}^{(j)} - \mu_i^{(j)})^2 + 2(x_{m,k}^{(j)} - \mu_{i-1}^{(j)})(\mu_{i-1}^{(j)} - \mu_i^{(j)})]} \\
 &= \sqrt{\frac{1}{iN} [(i-1)N\delta_{i-1}^{(j)} + \sum_{k=1}^N (x_{i,k}^{(j)} - \mu_{i-1}^{(j)})^2] + (\mu_{i-1}^{(j)} - \mu_i^{(j)})^2 - 2(\mu_{i-1}^{(j)} - \mu_i^{(j)})^2} \\
 &= \sqrt{\frac{1}{iN} [(i-1)N\delta_{i-1}^{(j)} + \sum_{k=1}^N (x_{i,k}^{(j)} - \mu_{i-1}^{(j)})^2] - (\mu_{i-1}^{(j)} - \mu_i^{(j)})^2} \\
 &= \sqrt{\delta_{i-1}^{(j)} + \frac{1}{i} [\frac{1}{N} \sum_{k=1}^N (x_{i,k}^{(j)} - \mu_{i-1}^{(j)})^2 - \delta_{i-1}^{(j)}] - (\mu_{i-1}^{(j)} - \mu_i^{(j)})^2}
 \end{aligned} \tag{3.8}$$

其中 $x_{i,k}^{(j)}$ 代表第 i 个 epoch 中第 k 个样本中的第 j 个参数, $\mu_i^{(j)}, \delta_i^{(j)}$ 分别表示第 i 个 epoch 中第 j 个参数的均值与方程, i 表示当前的回合数, N 表示每个 epoch 中的训练样本数。

3.4 基于贝塞尔轨迹辅助的 ARS 运动控制方法

本文提出了两种基于贝塞尔曲线辅助的 ARS 运动控制方法, 分别称为 ARS-Bezier(simple) 和 ARS-Bezier。这两种方法采用的奖励函数和策略函数与上文提到的基于纯 ARS 的控制方法相同, 但在动作空间的设计上有所不同。两种 ARS-Bezier 方法的动作空间为贝塞尔曲线的参数, 一旦获得这些参数, 智能体可以计算出相应的贝塞尔曲线轨迹, 并利用该轨迹计算各个电机的转动角度。然而, 实验发现虽然这两种方法在不同场景下均可以使智能体在较短时间内完成训练, 但习得的策略在不同场景下的迁移性较差, 即不具备通用性。尽管算法^[68]可以对神经网络进行组合, 从而学习到在不同场景下的运动策略, 但使机器人在不同场景下分别训练仍然是一项开销较大的工作。因此本文进一步通过随机化环境的方法。在训练时, 通过随机生成不同的地形, 使机器人能够学习到普适的越障行动策略。

(1) 状态空间: 在两种 ARS-Bezier 方法中, 状态空间额外添加了四条腿的摆动

信号，以帮助智能体了解机器人腿部的相位。状态空间定义如下：

$$s_t = (a_t, r, \vec{V}_{vel}, \vec{V}_{gyro}, \vec{V}_Q, \mathbf{c}_F, S(t)) \quad (3.9)$$

(2) 动作空间：两种 ARS-Bezier 方法的不同之处在于动作空间的设计。ARS-Bezier(simple) 与 Rahme 等人提出的方法相同^[46]，将贝塞尔曲线控制点中的 τ 和 ψ 作为动作空间的参数（见表2.1），即 $a^{simple} = (\tau, \psi)$ ，同时设置固定的 L_{span} （章节2.4）。然而，这种方法在不同场景中可能导致贝塞尔轨迹的形状大致相同，只是大小不同，这可能会降低机器人跨越障碍物的能力。

为了解决这个问题，本文进一步提出了 ARS-Bezier 方法。该方法根据贝塞尔轨迹的设计原理，通过控制点的重叠实现对腿部的牵引。相比于 ARS-Bezier(simple) 方法，ARS-Bezier 方法减少了不同控制点之间的限制，使得贝塞尔轨迹的形状更加多样化。因此，机器人能够更好地适应复杂的场景。在 ARS-Bezier 方法中，动作空间的参数 $a \in R^{12}$ ，当 $0 < S(t) < 1$ 时，贝塞尔曲线的控制点如表4.1所示；当 $1 < S(t) < 2$ 时，贝塞尔轨迹由公式3.10给出。

表 3.1 ARS-Bezier 算法的贝塞尔曲线控制点

控制点	坐标	控制点	坐标
P_0	$(a[0], 0)$	P_7	$(a[3], a[9])$
P_1	$(a[1], 0)$	P_8, P_9	$(a[4], a[9])$
P_2, P_3, P_4	$(a[2], a[7])$	P_{10}	$(a[5], 0)$
P_5, P_6	$(a[3], a[8])$	P_{11}	$(a[6], 0)$

$$\begin{aligned} X &= a[10](1 - 2S(t)) \\ Y &= a[11] \cos \frac{\pi(1 - 2S(t))}{2} \end{aligned} \quad (3.10)$$

其中 $a[0], a[1], a[2], a[11] < 0$, $a[4] \sim a[10] > 0$ 。

(3) 环境随机化方法：在每个 epoch 开始时，通过在地面放置随机高度的长方体可以实现环境随机化（如图3.2所示），在每个 epoch 结束时则会重置地形。具体来说，在 MuJoCo^[69] 仿真环境中，在起点附近不重叠地放置 450 个长宽均为 0.05 的长方体。每个回合开始时，将每个长方体的高度随机设定为一个介于 0 到 0.01 之间的随机数，即 $h_i \sim U(0, 0.01)$ 。

(4) 方法框架：本文提出的 ARS-Bezier 方法如图3.3所示，具体来说机器人的控制方法为：首先策略函数将输入的状态映射到动作空间（即贝塞尔曲线的参数），




图 3.2 MuJoCo 环境中的随机地形

之后贝塞尔轨迹生成器根据参数生成贝塞尔轨迹并根据四条腿的摆动信号 $S(t)$ 计算当前腿部末端点坐标，最后通过逆运动学的方法将坐标映射为各电机的转动角度，进而实现对机器人的控制。其中 ARS-Bezier(simple) 方法需要为贝塞尔轨迹生成器提供额外的控制参数 L_{span} ，即最大前进步长的一半。




图 3.3 ARS-Bezier 方法流程图

(5) 参数配置： ARS-Beizer 方法的训练参数配置如表3.2所示。

表 3.2 ARS-Bezier 算法参数

参数名称	参数大小	参数名称	参数大小
学习率 α	0.03	探索噪声 δ	0.05
每回合采样方向数 N	16	最佳方向数 b	10
回合最大步长	5000	训练回合数	500

3.5 本章小结

本章首先简要介绍了强化学习的基本概念和 ARS 算法，然后针对机器鼠的结构设计了 ARS 模型框架，包括动作空间、观测空间、策略函数和奖励函数等要素，接着将 ARS 算法与贝塞尔曲线相结合，提出了 ARS-Bezier 方法，并详细介绍了该方法的算法流程，最后在仿真环境中设计了环境随机化的方法，以使学习到的策略更具通用性。

4 实验结果与分析

4.1 引言

本章首先在 MuJoCo^[69] 仿真环境中对前文介绍的基于贝塞尔曲线的控制方法、基于强化学习的控制方法等进行了测试，并与本文提出的 ARS-Bezier 方法进行比较，接着对环境随机化的方法进行了测试和分析，最后介绍了机器鼠的硬件结构，并详细展示了在实际环境中搭建机器鼠并部署算法的过程。

4.2 仿真结果分析

4.2.1 仿真环境




图 4.1 MuJoCo^[69] 图形界面：界面左侧提供了实时操作功能，界面中间是仿真环境，界面右侧可以实时显示控制参数和传感器信息

本文采用了 MuJoCo 仿真环境进行机器鼠的仿真实验。MuJoCo 是一个多关节动力学接触仿真器，最初由华盛顿大学的 Emanuel 等人在 2012 年开发并发表^①。该仿真器于 2021 年 12 月被 DeepMind 收购，并于 2022 年 5 月开源^②，在官方网站提供了详细的 API 使用文档。MuJoCo 是用 C++ 编写的物理模拟库，支持多种

^① <https://MuJoCo.readthedocs.io/en/stable/overview.html>

^② <https://github.com/google-deepmind/MuJoCo>

语言，包括 C、C++ 和 Python，可以通过这些语言进行 API 调用。它具有高速、高精度、体积小和支持加速等优点，因此在研究领域得到了广泛应用。MuJoCo 具有复杂的动力学建模和编程能力，可以准确模拟现实世界中的碰撞、摩擦和力等物理效应。它可以用于实现基于模型的计算，例如机构设计、逆动力学数据分析以及机器学习的并行采样等应用场景。此外，MuJoCo 也可以作为传统的模拟器，用于游戏和交互式虚拟环境等场景。

在使用中，MuJoCo 环境中的模型通过统一机器人描述格式文件 (Unified Robot Description Format, URDF) 和可扩展标记语言 (XML) 定义，主要参数包括机器人形状材质质量、环境信息、传感器、驱动器以及重力摩擦系数等，同时通过 API 接口，用户可以在程序中随时修改这些参数，从而提供了更灵活的接口以供算法开发使用。与其他常见的模拟引擎不同，MuJoCo 不指定单位，因此用户可以根据需要自行改变单位以缩放模型。此外，MuJoCo 还提供了图形界面，可以实时显示机器人的运动情况，有助于用户进行开发和使用过程中的调试和可视化。

本文在仿真环境中使用的机器鼠与 NeRmo^[2] 实际的物理结构一致，包含四条绳驱结构的腿，每条腿包含两个自由度分别控制 yz 方向，此外机器鼠还包含一个自由度的头部、脊柱和两个自由度的尾部。在仿真环境中，机器鼠内部包含一个 IMU 传感器并且四条腿分别包含一个触力传感器。此外还在仿真环境中定义了多种运动场景如平地、木板、圆柱、随机地形等供机器鼠学习。

4.2.2 基于贝塞尔曲线控制方法



图 4.2 MuJoCo^[69] 仿真环境中机器鼠左前腿悬空

首先将机器鼠的腿部抽离并悬空，如图4.2所示，然后采用第2章中介绍的贝塞尔曲线轨迹控制方法来控制机器鼠的腿部运动。通过逆运动学的方法，将轨迹曲线转换为各电机的转动角度，从而实现对机器鼠的控制。这样做的目的是观察实际运动轨迹与规划轨迹之间的差异，进而验证在实现贝塞尔曲线控制的过程中是




图 4.3 机器鼠左前腿悬空状态下目标贝塞尔运动轨迹与实际运动轨迹的对比

否出现错误。

实验结果如图4.3所示，其中蓝色区域表示机器鼠腿部的可达范围，黄色曲线表示根据本节贝塞尔控制曲线设计的机器鼠腿部目标运动轨迹，红色曲线表示机器鼠腿部实际运动的轨迹。通过腿部悬空测试发现机器鼠腿部实际运动轨迹与目标贝塞尔轨迹基本重合。






图 4.4 仿真环境中的四个不同场景

接下来对机器鼠在不同场景下的运动情况进行了测试。本文共设计了四种不同的运动训练场景，如图4.4所示：场景 1 为基础平地环境；场景 2 在平地上每隔



(a) 运动距离



(b) 前进速度

图 4.5 平地仿真环境中机器鼠的运动情况

0.2 的距离放置一个尺寸为 0.2 米长、0.05 米宽、0.01 米高的木板；场景 3 为斜坡场景，由多个倾斜角度为 10 度的木板拼接而成；场景 4 中在平地上每隔 0.15 的距离放置半圆柱形障碍物，其半径为 0.1 米。

实验首先在平地场景下（场景 1）对比了基于贝塞尔曲线的腿部控制方法与简单的椭圆控制方法（即将腿部运动的轨迹设为椭圆形）。实验结果如图 4.5 所示，可以发现相比椭圆轨迹的控制方法，基于贝塞尔曲线的方法可以使机器鼠的运动更加平稳。在运动过程中，机器鼠的距离变化更加平稳且速度变化幅度更小。

最后在有障碍场景中（场景 2-4）进行测试，如图 4.6 所示。通过实验发现，基于贝塞尔曲线的运动控制方法只能让机器鼠通过场景 4 中的半圆柱形障碍物，而基于椭圆轨迹的控制方法则导致机器鼠无法通过任何障碍物。通过观察，发现在运动过程中，机器鼠的腿部会被障碍物卡住，从而导致机器鼠无法继续前进。

4.2.3 基于强化学习的控制方法

本节对比了在不同场景下,使用第3章提出的 ARS-poe、ARS-end、ARS-Bezier、ARS-Bezier(simple) 的训练效果,同时也与传统的 PPO^[34]算法进行了对比(其中 PPO-end、PPO-pos 与 ARS-end、ARS-pos 类似,分别以电机转动角度和腿部末端点坐标为动作空间)。图4.7展示了四个场景中训练轮次与机器人在 5000 步内前进距离的关系,图中的虚线代表使用纯贝塞尔轨迹的控制方法(2.4章)在对应场景下运动 5000 步的前进距离。

实验结果显示 ARS-Bezier 方法优于纯贝塞尔轨迹的控制方法,经过训练能够成功跨越各种障碍。与其他强化学习方法相比,ARS-Bezier 方法在训练初期就展现出相对较好的性能,并且可以更快地收敛,训练过程也更加稳定,这可能是由于贝塞尔曲线提供了较好的初始解。然而,实验也观察到使用 ARS-Bezier 方法时机器人可前进的最大距离小于其他强化学习方法。这是因为 ARS-Bezier 方法使用了贝塞尔曲线,而机器人的运动速度受到摆动信号的限制,在未来也可以进一步研究摆动信号对 ARS-Bezier 方法的影响。图中虚线表示在相同摆动信号下使用纯贝塞尔轨迹的控制方法的前进距离,ARS-Bezier 方法的性能可以超过这一基准。实验结果还表明,与类似文章^[46]中的 ARS-Bezier(simple)方法相比,本文提出的 ARS-Bezier 方法具有更好的性能。此外,传统强化学习方法如 PPO 大多需要借助 GPU 进行计算,而 ARS 算法则不需要,因此 ARS 算法在训练和推理过程中的计算开销较小。

4.2.4 环境随机化实验结果

在本节中首先环境随机化场景中分别使用 ARS-Bezier(simple)和 ARS-Bezier 方法训练了机器鼠。然后使用学习到的运动策略在三个带有障碍物的场景下进行测试。图4.8展示了两种 ARS-Bezier 方法的训练过程,表格4.1展示了不同方法学到的策略在各个场景下运动 5000 步后的前进距离,图4.9和4.10展示了这 5000 步中机器鼠的运动情况。通过实验发现,两种 ARS-Bezier 算法都能使机器鼠成功跨越场景 2 中的长方体障碍物和场景 4 中的圆柱障碍物,但在场景 3 中的上下坡环境中会出现摔倒的情况,因此尽管使用环境随机化的方法仍然需要针对不同场景进行适当的微调。实验结果还表明,ARS-Bezier 的平均表现优于 ARS-Bezier(simple)。

为了进一步评估习得策略的泛化性,本文在场景 2 和场景 4 下测试了机器鼠能够通过障碍物的最大高度,实验结果如表4.2所示。实验发现 ARS-Bezier 方法相比 ARS-Bezier(simple)能够通过更复杂的障碍物,具有更强的泛化能力。

表 4.1 不同场景下机器鼠前进距离

场景	ARS-Bezier	ARS-Bezier(simple)
场景 2	0.7291	0.5545
场景 3	0.8852	0.2562
场景 4	0.7320	0.8438

表 4.2 不同场景下机器鼠能通过的最大障碍物高度

场景	ARS-Bezier	ARS-Bezier(simple)
场景 2	0.19	0.15
场景 4	0.12	0.11

4.2.5 实验结果分析

本小节对几种不同的 ARS-Bezier 方法在平地运动的实验结果进行分析。为了方便表示在图表中使用 complex 和 simple 代替 ARS-Bezier 和 ARS-Bezier (simple) 方法，用 random 表示使用随机地形训练。


许超斌等人^[70]曾提出基于贝塞尔轨迹的控制方法可能导致机器人在运动过程中产生横向位置偏移。因此，本文比较了几种不同策略下，机器鼠在前进过程中的横向偏移大小。实验结果如图4.11所示。实验结果发现，相比过去的 ARS-Bezier(simple) 方法，本文提出的 ARS-Bezier 方法在运动过程中横向偏移更小，具有更高的稳定性。

此外，几种不同控制方法下机器鼠前进过程中三轴加速度的变化曲线如图4.12所示。在此基础上计算了每种控制方法三轴加速度的标准差，并将结果列在表4.3中。实验结果显示，ARS-Bezier 方法相比 ARS-Bezier(simple) 方法，加速度的标准差更小，说明 ARS-Bezier 控制方法更加稳定。


表 4.3 不同策略下前进过程中的三轴加速度标准差

complex	simple	complex, random	simple, random
6.38	8.95	5.48	8.08
6.18	8.24	5.80	7.07
7.78	11.71	6.77	11.06


观察实验还可发现，ARS-Bezier(simple) 方法在控制过程中，12 个控制点的变化不大，而 ARS-Bezier 方法的 12 个控制点随着运动会逐渐产生变化。然而，ARS-Bezier(simple) 方法的效果和稳定性均不如 ARS-Bezier 方法，这表明 ARS-Bezier 在训练过程中可能陷入局部最优解，进一步验证了上一章提到的“ARS-Bezier(simple) 方法的控制点整体形状始终大致相同可能会降低机器人的灵活性”。




(a) 场景 2：基于贝塞尔轨迹的控制方法




(b) 场景 2：基于椭圆轨迹的控制方法




(c) 场景 3：基于贝塞尔轨迹的控制方法



(d) 场景 3：基于椭圆轨迹的控制方法




(e) 场景 4：基于贝塞尔轨迹的控制方法




(f) 场景 4：基于椭圆轨迹的控制方法


图 4.6 有障碍物场景下机器鼠的左前腿末端点运动轨迹：两列分别代表使用基于贝塞尔轨迹的控制方法和基于椭圆轨迹的控制方法，三行分别代表三种不同障碍场景




(a) 场景 1



(b) 场景 2



(c) 场景 3



(d) 场景 4

图 4.7 各场景下不同算法的训练过程




图 4.8 随机环境下的训练过程







图 4.9 机器鼠在仿真环境中通过障碍物的状态示意图：两列分别代表使用 ARS-Bezier(simple) 算法和 ARS-Bezier 算法，三行分别代表三种不同障碍场景




(a) 场景 2: ARS-Bezier(simple)




(b) 场景 2: ARS-Bezier




(c) 场景 3: ARS-Bezier(simple)



(d) 场景 3: ARS-Bezier



(e) 场景 4: ARS-Bezier(simple)



(f) 场景 4: ARS-Bezier

图 4.10 有障碍物场景下机器鼠的左前腿末端点运动轨迹：两列分别代表使用 ARS-Bezier(simple) 算法和 ARS-Bezier 算法，三行分别代表三种不同障碍场景




图 4.11 不同策略下前进过程中的横向偏移




图 4.12 不同策略下前进过程中的三轴加速度

4.3 实物验证

4.3.1 硬件平台




图 4.13 机器鼠 NeRmo Lite 结构

本文的实验硬件平台采用了实验室研发的机器鼠 NeRmo Lite^[2]，其组成器件如图4.13所示。机器鼠主要包含 11 个数字舵机，其中每条腿包含两个舵机，头部、脊椎和尾部各自包含一个舵机。此外，硬件平台还包括 ESP8266-01s 主控板、伺服驱动器、电池和电压转换器。

NeRmo 相比传统四足机器人主要有以下几点不同。首先，由于 NeRmo 作为小型机器人内部空间较小，在肘关节处难以像大型机器人那样放置舵机。因此，NeRmo 创新性地采用了绳驱结构，将肘关节处的电机转移到大腿根部，并通过细绳连接舵机和脚部，从而实现对腿部的牵引。这种设计不仅减轻了腿部的重量，还有效地解决了空间限制的问题。其次，NeRmo 采用了柔性脊柱机构。相比过去大型四足机器人的刚性脊柱，NeRmo 的运动速度更快且更加灵活。通过脊柱的转动，

NeRmo 补足了腿部缺少的一个自由度，从而实现机器人的转向。

机器鼠的控制系统由 ESP8266-01s 主控板和伺服驱动器组成。ESP8266-01s 主控板是一款低成本、高性能的 Wi-Fi 微控制器，具有良好的可编程性和稳定性。它通过与伺服驱动器的通信，实现对各个舵机的控制和调节。伺服驱动器负责接收主控板发送的控制信号，并将其转换为相应的电流输出给舵机，以实现舵机的精确控制。为确保系统正常运行，机器鼠采用了电压转换器和电池供电。电压转换器用于将电池提供的直流电压转换为舵机和主控板所需的工作电压，以满足各个组件的工作要求。

4.3.2 机器人搭建流程




图 4.14 实际搭建的机器鼠图片

机器鼠 NeRmo 主要包括四条腿、头部、脊椎和尾部各一个，以及位于机器鼠中心的控制器和电源。下面分别介绍各部分的搭建过程：

(1) 电源：机器鼠的电源包括一个 7.4V 500mAh 的可充电锂电池和一个 6.0V/5A 的稳压器，如图4.15所示，电源为控制器提供供电。

(2) 控制器：控制器由 ESP8266-01s 主控板和伺服驱动器 PWM-PCA9685 组成，如图4.16所示。在实际控制中，主机通过 WiFi 与 ESP 建立 UDP 连接并发送控制信号，ESP 通过 PWM 向各个舵机发送控制信号，从而实现对机器人的控制。

(3) 腿部：由于前后腿结构相似，这里以左前腿为例进行介绍，如图4.17所示。每条腿包含两个电机，A 点的电机直接控制大腿根部的转动，而 B 点的电机通过细绳与腿部相连，通过细绳的牵引来控制腿部的第二个自由度。为了验证结构的正确性，实验中首先针对单条腿进行测试，观察腿部的实际运动轨迹与目标控制轨迹之间的差异。图4.17中的红色曲线展示了规划的目标曲线，为了方便展示，图中用蓝色星号表示腿部在实际运动中达到的若干位置。可以看出，实际运动轨迹与目标轨迹存在一定的误差，但误差较小，仍在可接受范围内。




图 4.15 机器鼠电气元件的简化原理图




图 4.16 机器鼠各器件间的连接方法：图中红字表示该器件的名称，黄色和绿色的线段表示连线情况

(4) 头部、脊椎与尾巴：头部、脊椎和尾巴的控制方式相似，通过两个细绳分别穿过组件的两侧，并与电机相连，当电机转动时，一侧的细绳被拉紧，而另一侧的细绳被放松，从而使这些组件向一侧摆动。由于本文主要研究小型四足机器人的运动方式，而许多机器人并不具备头部、脊椎和尾巴的自由度，因此在实验中并未对这三部分的电机进行控制。

4.3.3 实机测试

最后将运动策略烧入机器鼠并在实际环境中进行测试，实验结果如图4.18，实验结果表明机器人可以较为流畅灵活地前进。




图 4.17 机器鼠左前腿实际控制情况：图中红色曲线为左前腿控制的目标曲线，蓝色星号位置表示机器人在实际运动中所达到的位置




图 4.18 机器鼠在实际环境中运动情况：子标题代表开始运动的时间，图中蓝色点代表腿部末端点在运动中实际到达的位置，红色线条代表腿部末端点运动轨迹

4.4 结论

本章通过实验验证了提出的 ARS-Bezier 方法的有效性。首先在仿真环境中进行了对比实验，证明了 ARS-Bezier 方法的优势。随后将 ARS-Bezier 方法与环境随机化方法相结合，并在不同场景下进行了实验分析。最后在实际场景中介绍了搭建机器鼠和将控制算法烧入机器鼠的流程，并展示了将运动策略部署在实际机器鼠上的运动效果。

5 总结与展望

5.1 总结

传统四足机器人运动控制方法基于建模计算,需要针对不同场景分别设计、计算和调试,设计难度和工作量较大。为了使四足机器人能够更好地自主运动从而部署在实际应用场景,强化学习的控制方法已成为机器人运动控制的主流方法。为了使强化学习能够更好地应用于小型四足机器人,本文以实验室自研机器鼠 NeRmo 为平台,研究了轻量级的强化学习控制方法。同时通过轨迹调制辅助的方法提升强化学习模型的性能并降低学习难度。本文的主要研究内容如下:

(1) 针对机器鼠 NeRmo 的结构进行了机器人运动学分析,并分析介绍了机器鼠的硬件结构与控制原理。

(2) 分析证明了贝塞尔曲线的基本性质,并指出了先前论文中的不足之处。同时在机器鼠上实现了基于贝塞尔轨迹的控制方法,并在不同场景下进行了实验测试。实验证明,尽管贝塞尔轨迹控制方法优于椭圆轨迹控制方法,但仍然无法让机器鼠很好地跨越各种障碍。

(3) 针对机器鼠的结构,设计了基于轻量级算法 ARS 的强化学习框架。同时将贝塞尔轨迹引入 ARS 算法中,提出了 ARS-Bezier 方法。通过轨迹辅助的方法,提升模型的学习能力并降低学习难度。进一步设计了在随机环境中训练的方法,使智能体可以学习到更加普适的运动策略。

(4) 在仿真环境中进行了一系列对比实验。首先证明了 ARS-Bezier 方法的有效性和优越性。相比其他的强化学习方法,ARS-Bezier 方法能够更快地收敛,并且无需 GPU,在计算开销上远小于传统强化学习方法。接着分析了在随机环境中学习到的运动策略在不同场景下的表现情况,并证明了方法的有效性。

5.2 展望

四足机器人运动控制是一个多学科交叉的领域,涉及设计计算机科学、电子信息与通信、人工智能、数学物理建模、优化、机械、仿生等各个领域。本文的研究结果尚未完备,仍存在一些不足和值得改进的地方:

(1) 奖励函数的改进:本文设计的奖励函数比较简单,实验中发现机器鼠有时会出现跌倒、前进方向偏移等问题。在未来的研究中,可以考虑通过设计合适的

奖励函数进一步改进方法。

(2) 环境随机化的改进: 本文设计的环境随机化在一定程度上提升了运动策略的普适性。然而, 通过实验也发现, 在不进行微调的情况下, 这种方法无法保证机器鼠能够通过所有障碍物。这可能是由于障碍物与随机环境之间存在较大差异所导致的, 目前的随机环境由若干个高度不同的长方体组成, 后续可以考虑进行适当改进, 以提高方法的适应性。

(3) 贝塞尔轨迹与 ARS 方法结合的改进: 本文提出的两种 ARS-Bezier 方法属于两个极端。ARS-Bezier(simple) 的动作空间仅有 2 个维度, 严重限制了贝塞尔轨迹的形状; 而 ARS-Bezier 方法的动作空间达到 12 维, 对于轨迹形状仅做很少的限制, 但动作空间的增加也可能导致训练难度与计算开销增大。在未来的研究中, 可以进一步探索是否存在更好的结合方案, 以平衡轨迹形状的灵活性和控制方法的效果。

(4) 摆动信号对 ARS-Bezier 方法的影响: 实验中发现目前提出的 ARS-Bezier 方法前进的最大距离不如其他强化学习方法, 这可能是由于贝塞尔轨迹控制方法中摆动信号直接影响着运动速度。在未来可以进一步研究摆动信号对于方法速度、稳定性、收敛速度等方面的影响。

参考文献

- [1] REILLY K. From automata to automation: The birth of the robot in rurs (rossum's universal robots)[M]//Automata and Mimesis on the Stage of Theatre History. Springer, 2011: 148-176.
- [2] BING Z, ROHREGGER A, WALTER F, et al. Lateral flexion of a compliant spine improves motor performance in a bioinspired mouse robot[J]. Science Robotics, 2023, 8(85): eadg7165.
- [3] MOSHER R. Test and evaluation of a versatile walking truck[C]//Proceedings of Off-Road Mobility Research Symposium, Washington DC, 1968. 1968: 359-379.
- [4] MCGHEE R B. Finite state control of quadruped locomotion[J]. Simulation, 1967, 9(3): 135-140.
- [5] HIROSE S. Some considerations on a feasible walking mechanism as a terrain vehicle[C]//Proc. 3rd CISM-IFTOMM Int. Symp. on Theory and Practice of Robotics and Manipulators, 1978. 1978: 357-375.
- [6] HIROSE S. The basic motion regulation system for quadruped walking vehicle[C]//Proc. ASME Design Engineering Technical Conf. 1981.
- [7] HIROSE S, KATO K. Study on quadruped walking robot in tokyo institute of technology-past, present and future[C]//Proceedings 2000 ICRA. Millennium Conference. IEEE International Conference on Robotics and Automation. Symposia Proceedings (Cat. No. 00CH37065): Vol. 1. IEEE, 2000: 414-419.
- [8] BUEHLER M, COCOSCO A, YAMAZAKI K, et al. Stable open loop walking in quadruped robots with stick legs[C]//Proceedings 1999 IEEE International Conference on Robotics and Automation (Cat. No. 99CH36288C): Vol. 3. IEEE, 1999: 2348-2353.
- [9] MURPHY M P, SAUNDERS A, MOREIRA C, et al. The littledog robot[J]. The International Journal of Robotics Research, 2011, 30(2): 145-149.
- [10] RAIBERT M, BLANKESPOOR K, NELSON G, et al. Bigdog, the rough-terrain quadruped robot[J]. IFAC Proceedings Volumes, 2008, 41(2): 10822-10825.
- [11] DYNAMICS B. About the spot robot[EB/OL]. 2022. <https://support.bostondynamics.com/s/article/About-the-Spot-robot>.
- [12] DYNAMICS B. Introducing wildcat[EB/OL]. 2013. <https://www.youtube.com/watch?v=wE3fmFTtP9g>.
- [13] SEOK S, WANG A, CHUAH M Y, et al. Design principles for energy-efficient legged locomotion and implementation on the mit cheetah robot[J]. Ieee/asme transactions on mechatronics, 2014, 20(3): 1117-1129.
- [14] KATZ B, DI CARLO J, KIM S. Mini cheetah: A platform for pushing the limits of dynamic quadruped control[C]//2019 international conference on robotics and automation (ICRA). IEEE, 2019: 6295-6301.

- [15] HUTTER M, GEHRING C, JUD D, et al. Anymal-a highly mobile and dynamic quadrupedal robot[C]//2016 IEEE/RSJ international conference on intelligent robots and systems (IROS). IEEE, 2016: 38-44.
- [16] 马培荪, 陆顺寿, 何奇伟. 四足步行机器人的运动和结构设计[J]. 机械设计与研究, 1991(4): 34-39.
- [17] HUANG B, WANG P, SUN L. Behavior-based control of a hybrid quadruped robot[C]//2006 6th World Congress on Intelligent Control and Automation: Vol. 2. IEEE, 2006: 8997-9001.
- [18] GUAN X, ZHENG H, ZHANG X. Biologically inspired quadruped robot biosbot: modeling, simulation and experiment[C]//2nd International Conference on Autonomous Robots and Agents. Citeseer, 2004: 261-266.
- [19] 李川. 四足仿生机器人跑跳运动规划与控制[D]. 浙江大学, 2017.
- [20] 房晓楠. 宇树科技王兴兴: 让四足机器人真正走进大众生活[J/OL]. 机器人产业, 2021 (111-116). DOI: 10.19609/j.cnki.cn10-1324/tp.2021.04.019.
- [21] SHI Q, GAO J, WANG S, et al. Development of a small-sized quadruped robotic rat capable of multimodal motions[J]. IEEE Transactions on Robotics, 2022, 38(5): 3027-3043.
- [22] TENCENT. Tencent robotics x[EB/OL]. 2018. <https://roboticsx.tencent.com/#/>.
- [23] 小米. CyberDog 仿生四足机器人[EB/OL]. 2021. <https://www.mi.com/cyberdog>.
- [24] 云深科技绝影. 绝影 X20[EB/OL]. 2022. <https://deeprobotics.cn/robot/index/product.html>.
- [25] WINKLER A W, FARSHIDIAN F, NEUNERT M, et al. Online walking motion and foothold optimization for quadruped locomotion[C]//2017 IEEE International Conference on Robotics and Automation (ICRA). IEEE, 2017: 5308-5313.
- [26] 蒋振宇. 基于 SLIP 模型的四足机器人对角小跑步态控制研究[D]. 哈尔滨工业大学, 2014.
- [27] 白柳, 罗金良, 胡鹏飞, 等. 虚拟模型控制被动柔性脊柱四足机器人研究[J]. 机电工程技术, 2022.
- [28] 张洪记. 基于模型预测控制的四足机器人运动控制研究[D]. 哈尔滨工业大学, 2020.
- [29] KOBER J, BAGNELL J A, PETERS J. Reinforcement learning in robotics: A survey[J]. The International Journal of Robotics Research, 2013, 32(11): 1238-1274.
- [30] HUA J, ZENG L, LI G, et al. Learning for a robot: Deep reinforcement learning, imitation learning, transfer learning[J]. Sensors, 2021, 21(4): 1278.
- [31] ENDO G, MORIMOTO J, MATSUBARA T, et al. Learning cpg-based biped locomotion with a policy gradient method: Application to a humanoid robot[J]. The International Journal of Robotics Research, 2008, 27(2): 213-228.
- [32] MNIEH V, KAVUKCUOGLU K, SILVER D, et al. Playing atari with deep reinforcement learning [A]. 2013.
- [33] BABAEIZADEH M, FROSIO I, TYREE S, et al. Reinforcement learning through asynchronous advantage actor-critic on a gpu[A]. 2016.
- [34] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms[A]. 2017.

- [35] ASADA M, NODA S, TAWARATSUMIDA S, et al. Purposive behavior acquisition for a real robot by vision-based reinforcement learning[J]. Machine learning, 1996, 23: 279-303.
- [36] HAARNOJA T, ZHOU A, ABBEEL P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]//International conference on machine learning. PMLR, 2018: 1861-1870.
- [37] 郭宪, 方勇纯. 仿生机器人运动步态控制: 强化学习方法综述[J]. 智能系统学报, 2020, 15 (1): 152-159.
- [38] WANG Y, JIA W, SUN Y. A hierarchical reinforcement learning framework based on soft actor-critic for quadruped gait generation[C]//2022 IEEE International Conference on Robotics and Biomimetics (ROBIO). IEEE, 2022: 1970-1975.
- [39] TORREY L, SHAVLIK J. Transfer learning[M]//Handbook of research on machine learning applications and trends: algorithms, methods, and techniques. IGI global, 2010: 242-264.
- [40] VILALTA R, DRISSI Y. A perspective view and survey of meta-learning[J]. Artificial intelligence review, 2002, 18: 77-95.
- [41] BENGIO Y, LOURADOURE J, COLLOBERT R, et al. Curriculum learning[C]//Proceedings of the 26th annual international conference on machine learning. 2009: 41-48.
- [42] THRUN S. Lifelong learning algorithms[M]//Learning to learn. Springer, 1998: 181-209.
- [43] FINN C, RAJESWARAN A, KAKADE S, et al. Online meta-learning[C]//International Conference on Machine Learning. PMLR, 2019: 1920-1930.
- [44] IJSPEERT A J. Central pattern generators for locomotion control in animals and robots: a review [J]. Neural networks, 2008, 21(4): 642-653.
- [45] SHI H, ZHOU B, ZENG H, et al. Reinforcement learning with evolutionary trajectory generator: A general approach for quadrupedal locomotion[J]. IEEE Robotics and Automation Letters, 2022, 7(2): 3085-3092.
- [46] RAHME M, ABRAHAM I, ELWIN M L, et al. Linear policies are sufficient to enable low-cost quadrupedal robots to traverse rough terrain[C]//2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2021: 8469-8476.
- [47] RADFORD A, NARASIMHAN K, SALIMANS T, et al. Improving language understanding by generative pre-training[M]. OpenAI, 2018.
- [48] ZHAO Z, CHEN T, MENG F, et al. Finding the missing data: A bert-inspired approach against package loss in wireless sensing[A]. 2024.
- [49] CAI Z, CHEN T, ZHOU F, et al. Falldewideo: Vision-aided wireless sensing dataset for fall detection with commodity wi-fi devices[C]//Proceedings of the 3rd ACM MobiCom Workshop on Integrated Sensing and Communications Systems. 2023: 7-12.
- [50] ZENG M, TAN X, WANG R, et al. Musicbert: Symbolic music understanding with large-scale pre-training[A]. 2021.
- [51] CHOU Y H, CHEN I, CHANG C J, et al. Midibert-piano: large-scale pre-training for symbolic music understanding[A]. 2021.

- [52] CHEN L, SINAVSKI O, HÜNERMANN J, et al. Driving with llms: Fusing object-level vector modality for explainable autonomous driving[A]. 2023.
- [53] FU D, LI X, WEN L, et al. Drive like a human: Rethinking autonomous driving with large language models[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2024: 910-919.
- [54] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[J]. Advances in neural information processing systems, 2022, 35: 27730-27744.
- [55] HUANG W, WANG C, ZHANG R, et al. Voxposer: Composable 3d value maps for robotic manipulation with language models[A]. 2023.
- [56] SAKIB M S, SUN Y. Consolidating trees of robotic plans generated using large language models to improve reliability[A]. 2024.
- [57] HWANGBO J, LEE J, DOSOVITSKIY A, et al. Learning agile and dynamic motor skills for legged robots[J]. Science Robotics, 2019, 4(26): eaau5872.
- [58] MANIA H, GUY A, RECHT B. Simple random search provides a competitive approach to reinforcement learning[A]. 2018.
- [59] HYUN D J, SEOK S, LEE J, et al. High speed trot-running: Implementation of a hierarchical controller using proprioceptive impedance control on the mit cheetah[J]. The International Journal of Robotics Research, 2014, 33(11): 1417-1445.
- [60] MAES L D, HERBIN M, HACKERT R, et al. Steady locomotion in dogs: temporal and associated spatial coordination patterns and the effect of speed[J]. Journal of Experimental Biology, 2008, 211(1): 138-149.
- [61] LI Y. Deep reinforcement learning: An overview[A]. 2017.
- [62] LEVINE S, FINN C, DARRELL T, et al. End-to-end training of deep visuomotor policies[J]. Journal of Machine Learning Research, 2016, 17(39): 1-40.
- [63] FINN C, ABBEEL P, LEVINE S. Model-agnostic meta-learning for fast adaptation of deep networks[C]//International conference on machine learning. PMLR, 2017: 1126-1135.
- [64] SCHULMAN J, LEVINE S, ABBEEL P, et al. Trust region policy optimization[C]//International conference on machine learning. PMLR, 2015: 1889-1897.
- [65] ZHANG Z, HUANG Y, ZHAO Z, et al. A hierarchical reinforcement learning approach for adaptive quadruped locomotion of a rat robot[C]//2023 IEEE International Conference on Robotics and Biomimetics (ROBIO). IEEE, 2023: 1-6.
- [66] DEGRIS T, PILARSKI P M, SUTTON R S. Model-free reinforcement learning with continuous action in practice[C]//2012 American Control Conference (ACC). IEEE, 2012: 2177-2182.
- [67] LILLICRAP T P, HUNT J J, PRITZEL A, et al. Continuous control with deep reinforcement learning[A]. 2015.
- [68] YU L, YU B, YU H, et al. Language models are super mario: Absorbing abilities from homologous models as a free lunch[A]. 2023.
- [69] TODOROV E, EREZ T, TASSA Y. Mujoco: A physics engine for model-based control[C]//2012

- IEEE/RSJ international conference on intelligent robots and systems. IEEE, 2012: 5026-5033.
- [70] 许超斌, 李霖智, 杜俊龙, 等. 基于贝塞尔曲线的四足机器人足端轨迹规划研究[J/OL]. 机械强度, 2023, 45: 708-714. DOI: 10.16579/j.issn.1001.9669.2023.03.028.

致谢

四年本科时光匆匆而逝，我从中受益良多。从深圳校区到广州校区、从明德园到至善园，我在众多博学多识的老师的课堂和实验室中汲取了丰富的知识，结实了许多志同道合的朋友与队友。这四年的时光是我过去人生中最充实的阶段，我由衷地向我遇到的所有老师、同学以及母校表达感谢。

在此我要特别感谢我的毕业设计导师陈刚教授和黄凯教授。在整个毕业设计的过程中，他们给予了我巨大的帮助，并提供了宝贵的实验平台与资源。我还要特别感谢课题组张子韬师兄，他是我科研道路上的引路人，向我传授了宝贵的经验，并一直引导我克服各种困难，在毕业设计和学习上，他都给予了我许多帮助和鼓励。感谢刘宁教授和高成英教授，在本科期间给我提供了科研的机会，使我能够将专业知识与我的音乐爱好结合，让我发现了人工智能的魅力，并确定了未来的学习和职业规划，感谢课题组的梁潇师姐和韦舒心师姐，在科研道路对我的指导与无私付出。感谢深圳大数据研究院朱光旭博士、李航博士、李晓阳博士以及课题组的各位师兄、同学：陈廷尉、蔡智捷、陈罕之、孟繁一、江一航、王衍滔、李昕昊、陈浩洸、张一楠。在我过去一年的访问学习期间，他们的帮助使我在生活、学习和科研方面都取得了巨大的成长。感谢广州似然实验室为我提供了宝贵的学习机会，特别感谢实验室导师刘铭文、梁智鹏、马骁腾以及课题组的各位师兄。

感谢我的家人朋友们作为我坚实的后盾为我默默付出，使我能够安心求学，追求自己喜欢的事物。

感谢我的母校中山大学，“博学审问慎思明辨笃行”的校训培养了我乐于探索的生活习惯，“要做大事而不要做大官”的教诲我会铭记终生，我将带着母校培养的优良品质继续追求知识，开启下一段学习旅程。

最后感谢百忙之中对本文进行评审、提出宝贵意见的专家老师。

赵子健

2024年5月9日

在读期间发表的学术论文与取得的研究成果

已发表论文

- [1] Zijian Zhao, Tingwei Chen, Fanyi Meng, Hang Li, XiaoYang Li, Guangxu Zhu*, “Finding the Missing Data: A BERT-inspired Approach Against Package Loss in Wireless Sensing”, IEEE International Conference on Computer Communications (INFOCOM) DeepWireless Workshop 2024.
- [2] Xiao Liang, Zijian Zhao, Weichao Zeng, Yutong He, Fupeng He, Yiyi Wang, Chengying Gao*, “PianoBART: Symbolic Piano Music Understanding and Generating with Large-Scale Pre-Training”, IEEE Conference on Multimedia Expo (ICME) 2024. (oral)
- [3] Zitao Zhang, Yuhong Huang, Zijian Zhao, Chenglin Cai, Zhenshan Bing, Alois Knoll and Kai Huang*, “Autonomous Locomotion of a Rat Robot Based on Model-free Reinforcement Learning”, IEEE International Conference on Advanced Robotics and Mechatronics (ICARM) 2024.
- [4] Zitao Zhang, Yuhong Huang, Zijian Zhao, Zhenshan Bing, Alois Knoll and Kai Huang*, “A Hierarchical Reinforcement Learning Approach for Adaptive Quadruped Locomotion of a Rat Robot”, IEEE International Conference on Robotics and Biomimetics (ROBIO) 2023. (Best Paper Award in Biomimetics Finalist)
- [5] Zitao Zhang*, Yuhong Huang, Zijian Zhao, Zhenshan Bing, Kai Huang, “Autonomous Locomotion of a Rat Robot Based on Reinforcement Learning”, China Intelligent Robotics Annual Conference (CIRAC) 2023.

待发表论文

- [1] Zijian Zhao, Tingwei Chen, Zhijie Cai, Hang Li, XiaoYang Li, Guangxu Zhu*, “CSi-Net: A Siamese Network for Cross-Domain Wi-Fi Sensing”, IEEE Transactions on Mobile Computing (TMC). (under review)
- [2] Tingwei Chen, Yantao Wang, Hanzhi Chen, Zijian Zhao, Xinhao Li, Nicola Piovesan, Guangxu Zhu*, Qingjiang Shi, “Modelling the 5G Energy Consumption using Real-world Data: Energy Fingerprint is All You Need”, IEEE Global Communications Conference (GLOBECOM) 2024. (under review)

授权专利

[1] 赵子健, 韩凯峰, 陈琪美, 朱光旭, 李晓阳, 李航, “信道状态信息恢复方法及装置、设备、存储介质” (深圳大数据研究院, 申请日: 2024.04.02, 申请号: 202410232125.0)

[2] 黄凯, 张子韬, 赵子健, 陶若怡, “一种基于强化学习的小型仿生鼠机器人的运动控制方法” (人工智能与数字经济广东省实验室 (广州) & 中山大学, 申请日: 2024.12.04, 申请号: 202311649978.6)